越复杂越好？

基于局部水平锚定岭回归的变压器油温预测

Is More Complex Better?
Transformer Oil Temperature Forecasting with Local-Level Anchored Ridge Regression

摘要

为预测电力变压器未来油温，本文在 ETTh1 小时级数据集上研究仅以历史油温为输入的单变量多步预测。通过数据分析与统计基线比较，发现近期油温水平能够为预测提供参考，但训练段与测试段的温度水平存在差异。为处理这一差异，构建局部水平锚定 Ridge（Anchored Ridge）模型：以最近 96 h 油温为输入，减去最近 24 h 的均值，利用多输出 Ridge 预测未来温度相对该均值的变化，再加回均值得到油温预测。实验比较统计基线、线性模型及循环网络和片段模型，并考察局部水平处理、历史长度与预测长度的影响。在固定时间划分下，该模型预测未来 96 h 的测试均方误差为 4.613 ℃^{2}，平均绝对误差为 1.632 ℃，较 24 h 局部均值基线降低 10.3%；其平均绝对误差低于所比较神经网络的三种子指标均值。保持 96 h 输入并分别预测未来 192、336 和 720 h 时，平均绝对误差分别为 1.914、2.129 和 2.116 ℃。结果表明，在本次实验所考察的预测长度下，结合局部水平处理与线性映射，仅凭历史油温即可得到平均绝对误差不超过 2.129 ℃ 的预测结果。

关键词：变压器油温；单变量预测；长序列预测；ETTh1；Ridge；局部水平锚定

Abstract

We study univariate multi-step forecasting of power-transformer oil temperature on the hourly ETTh1 dataset, using historical oil temperature as the sole input. Data analysis and statistical baselines show that recent temperatures provide a useful reference, while temperature levels differ between the training and test periods. To address this difference, we construct a local-level anchored Ridge predictor. The model subtracts the mean of the latest 24 hours from a 96-hour input window, uses multi-output Ridge regression to forecast future deviations from that mean, and restores the mean to obtain the temperature forecast. We compare statistical baselines, linear models, recurrent networks, and patch-based models, and examine local-level handling, history length, and forecast horizon. Under a fixed chronological split, the model achieves a test mean squared error of 4.613 °C^2 and a mean absolute error (MAE) of 1.632 °C for the next 96 hours. Its MAE is 10.3% lower than that of the 24-hour local mean baseline and lower than the mean MAEs across three training seeds of the neural models compared. With the same 96-hour input,

separately fitted models achieve MAEs of 1.914, 2.129, and 2.116 °C for horizons of 192, 336, and 720 hours, respectively. Across the evaluated horizons, local-level handling combined with a linear mapping yields a test MAE of at most 2.129 °C using historical oil temperature alone.

Keywords: transformer oil temperature; univariate forecasting; long-term forecasting; ETTh1; Ridge regression; local-level anchoring

1 引言

电力变压器运行时，油温随负荷与热状态变化。根据历史观测估计未来油温，是研究温度变化预警和设备运行安排的基础。Jiménez-Navarro 等围绕变压器油温预测构建了平滑残差网络，并同时考察误差与模型规模，说明预测精度和求解成本需要共同考虑 [1]。本研究以油温（Oil Temperature, OT）为唯一预测目标，关注根据连续历史记录生成未来温度序列的具体方法。

电力变压器数据集（Electricity Transformer Dataset, ETT）由 Informer 工作发布，记录油温与六个负荷变量，其中 ETTh1 为小时级数据 [2, 3]。围绕 ETT 的预测任务，Informer 官方实现将单变量输入、单变量输出记为 S 模式[1]。本文采用 S 模式，只使用 OT 历史预测未来 OT。

单变量油温预测已有明确的文献基础。Zeng 等在《Are Transformers Effective for Time Series Forecasting?》附录 C.1 中比较了 ETT 数据上的单变量长序列预测，并讨论了 ETTh1 训练段与测试段之间的分布变化 [4]。Nie 等在 PatchTST 论文附录 A.3 中明确将 ETT 的 oil temperature 作为单变量预测对象 [5]。这些研究为本文的 S 模式设置、预测长度和对照模型提供了直接依据。

在这一设置下，增加模型复杂度是否有助于降低油温误差，需要结合已有方法的机制判断。Informer、Autoformer 和 FEDformer 分别通过稀疏注意力、序列分解与频域计算处理长序列 [2, 6, 7]。Zeng 等同时展示了简单线性预测器的竞争力，并通过 NLinear 在预测前减去最后观测值、输出后加回该值，以减轻窗口间水平变化的影响 [4]。因而，线性预测和参考水平处理构成了本任务的直接起点。

片段模型提供了有代表性的结构对照。PatchTST 以局部片段作为输入单元，在单个通道内学习时间关系 [5]；SegRNN 通过片段级循环和并行多步预测压缩长序列计算 [8]。RevIN 则对每个输入窗口进行可逆的均值与尺度变换 [9]。Huang 等以 Ridge 为基础，在包括 ETTh1 的八个基准上搜索历史长度、局部归一化与正则化等设置，发现经过调节的线性模型能够与多种非线性模型竞争 [10]。Han 等从模型容量和分布变化的角度分析了通道独立建模的表现 [11]。这些研究为油温预测中的结构与预处理选择提供了依据。

ETTh1 中，历史温度水平是需要明确处理的信息。当前固定划分下，训练段约覆盖一年，测试段集中在晚秋至冬季，二者 OT 均值约为 17.13 ℃ 和 4.85 ℃。直接由历史映射未来绝对温度时，模型既要识别当前水平，又要学习未来变化。最近一天的油温均值能够提供局部参考，因此可将未来温度写成“当前局部水平加相对变化”，再由预测器学习相对变化。

基于上述研究，本文构建 Anchored Ridge 油温预测器：以最近 24 h 均值为参考，将 96 h 历史和未来目标同时中心化，学习历史残差到未来残差的线性映射。该方案沿用已有研究中的直接

[1]任务标记见 Informer 官方实现的参数说明：`https://github.com/zhouhaoyi/Informer2020`。

多步预测、参考水平恢复和线性建模思想，并针对 ETTh1 的 OT 任务组合这些处理。模型比较用于判断这一具体方案能否满足预测需要，以及更复杂结构能够带来多少额外误差变化。

本文的工作包括三个方面：一是明确 S 模式下的油温预测问题，构建从历史观测到未来温度序列的完整预测器；二是以统计预测、线性模型、循环网络和片段模型进行比较，分析水平处理与输入选择；三是给出最终预测方案，在 96 h 预测中取得 1.632 ℃ 的平均绝对误差，并评估其在更长预测区间上的表现。

2 数据与实验设置

2.1 数据集与油温特征

ETTh1 包含 2016 年 7 月至 2018 年 6 月的小时级变压器运行记录，共 17,420 个时刻 [3]。数据包含油温和六项负荷指标，本文以油温作为主要预测变量。图 1 展示油温随时间的变化及实验划分。

油温在相邻时刻具有较强持续性：训练段 1 h 和 24 h 滞后自相关分别为 0.994 和 0.940。按月份分组可解释训练段 81.1% 的油温方差；在此基础上加入小时分组，再解释 5.7% 的方差。训练、验证和测试段的油温均值分别为 17.13、15.58 和 4.85 ℃，反映出不同时间段的温度水平差异。这些特征为采用近期油温水平和历史窗口进行预测提供了依据。

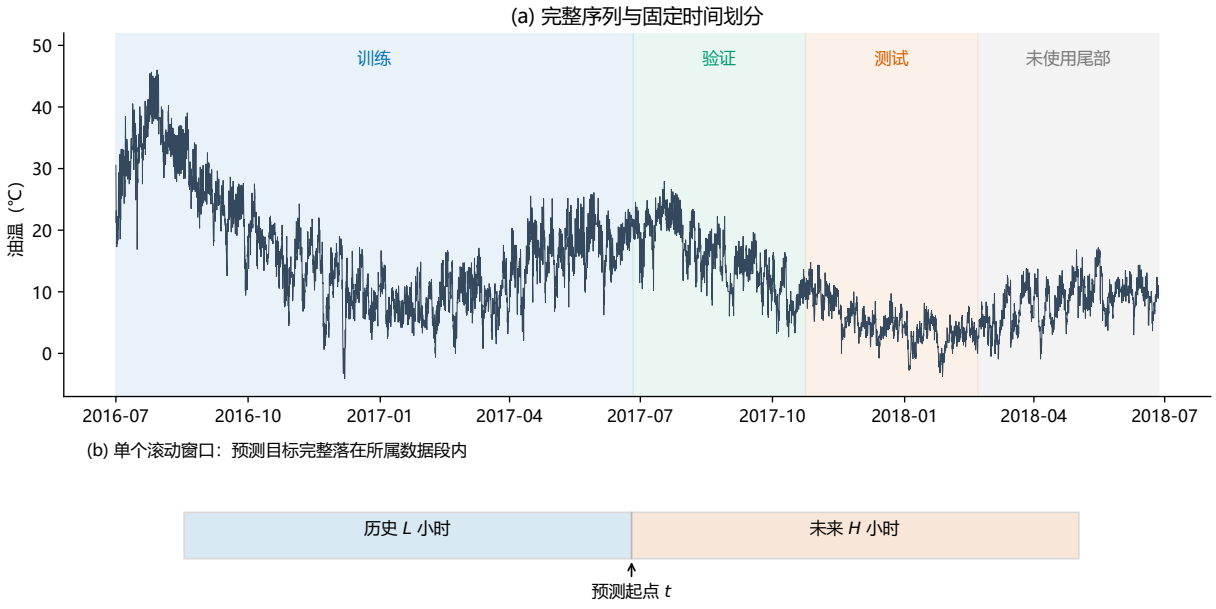


图 1: ETTh1 油温序列、时间划分与预测窗口。上图展示训练、验证、测试区间及未使用的数据；下图展示一次预测所需的历史观测和未来目标。

2.2 任务与滚动窗口

设小时油温为 y_t，历史长度为 L，预测长度为 H，单变量输入与目标定义为

$$\mathbf{x}_t = (y_{t-L+1}, \ldots, y_t)^\top \in \mathbb{R}^L, \qquad \mathbf{y}_t = (y_{t+1}, \ldots, y_{t+H})^\top \in \mathbb{R}^H. \tag{1}$$

单变量设置记为 S 模式。默认 $L = H = 96$，即根据过去 4 天预测未来 4 天。模型一次生成全部 H 个输出；预测期间使用同一输入窗口，逐步误差可按未来小时位置分别统计。

训练、验证和测试集沿用 Informer 对 ETTh1 的时间划分，按每月 30 天计算，分别取连续的 12、4 和 4 个月 [2, 12]。各段日期与样本数见表 1，表中每个日期范围均包含末日的 23:00。训练段最初的 96 h 用作历史输入，首个预测目标从第 97 h 开始。末尾 3,020 行不参与实验。窗口每次向前移动 1 h，训练窗口数为 $8640 - L - H + 1$，验证与测试各为 $2880 - H + 1$。

验证集的第一个预测目标从 2017 年 6 月 26 日 00:00 开始，其输入使用此前 96 h 已观测的油温。测试集同样以首个目标时刻之前的历史作为输入。所有验证或测试窗口的未来目标均完整位于对应数据段内；模型参数与标准化统计量由训练集确定。

表 1: 固定划分与默认 96 h 历史、96 h 预测的样本数。

数据段	行数	窗口数	行索引	日期范围
训练	8,640	8,449	$[0, 8640)$	2016-07-01 至 2017-06-25
验证	2,880	2,785	$[8640, 11520)$	2017-06-26 至 2017-10-23
测试	2,880	2,785	$[11520, 14400)$	2017-10-24 至 2018-02-20

长历史实验取 $L = 336$、$H = 96$；验证与测试目标及预测起点保持相同，训练窗口数降至 8,209。该设置为输入信息与历史长度比较提供共同的目标集合。

2.3 标准化与模型选择

所有固定尺度统计量均在训练窗口上拟合。按滞后标准化为输入的每个小时位置分别估计均值与标准差；按变量标准化则将所有训练窗口的时间位置合并，每个变量使用一个均值与标准差。表 2 给出各模型采用的方式。

表 2: 各模型的标准化方式。目标标准化发生在锚定之后；预测时先反标准化，再恢复输入窗口的参考水平。

模型	输入尺度	目标尺度
96 h Ridge	按滞后	保留油温残差单位
MLP、PatchTST、片段混合 MLP	按滞后	按预测步
GRU、LSTM	单变量合并时间位置	按预测步
DLinear、SegRNN	单变量合并时间位置	合并全部预测步
192/336/720 h Ridge	按滞后	按预测步

Ridge 正则化强度取 $\{0.1, 1, 10, 100, 1000\}$，按验证集平均绝对误差（Mean Absolute Error, MAE）选择。神经模型使用均方误差（Mean Squared Error, MSE）损失和 Adam 优化器。学习率为 10^{-3}，权重衰减为 10^{-4}，批量大小为 256，梯度范数裁剪阈值为 1。最多训练 300 轮，验证 MAE 连续 20 轮未改善时停止，并恢复验证 MAE 最低的参数。随机种子取 0、1、2，训练设备为 RTX 5090 Laptop GPU，软件为 PyTorch 2.14.1 与 CUDA 13.0。

不同模型采用表 2 所列的标准化方式。比较水平处理的作用时，同一模型的两个版本使用相同的标准化方式。

2.4 指标与统计比较

设测试窗口数为 N，误差 $e_{i,h} = \hat{y}_{i,h} - y_{i,h}$，则

$$\mathrm{MSE} = \frac{1}{NH}\sum_{i,h} e_{i,h}^2, \quad \mathrm{MAE} = \frac{1}{NH}\sum_{i,h} |e_{i,h}|, \quad \mathrm{Bias} = \frac{1}{NH}\sum_{i,h} e_{i,h}. \tag{2}$$

MSE 单位为 ℃^{2}，MAE 与平均偏差单位为 ℃。所有主结果在恢复原始油温单位后计算；正偏差表示整体高估。相对基线的 MAE 改善率定义为 $1 - \mathrm{MAE}_{\mathrm{model}}/\mathrm{MAE}_{\mathrm{ref}}$，正值表示误差较低。

每个神经模型使用三个随机种子训练。三种子指标均值是先计算每次训练的误差，再对三个误差取平均；其标准差使用样本标准差。预测集成先对三个模型的预测值逐点取平均，得到 $\hat{\mathbf{y}}^{\mathrm{ens}} = \frac{1}{3}\sum_{s=1}^{3} \hat{\mathbf{y}}^{(s)}$，再计算集成预测的误差。本文分别报告这两种结果。

比较两个模型时，先计算它们在同一测试窗口上的误差之差，再对所有窗口取平均。为了了解这个平均差值受测试时段变化的影响，采用块自助法估计区间：每次随机抽取若干段连续窗口，拼接至原测试窗口数，并重新计算平均差值；重复 2,000 次后，取结果的第 2.5 和第 97.5 百分位数作为 95% 区间。区间位于零的同一侧时，模型间误差差异的方向在重采样中较一致；区间跨零时，差异方向不够稳定。例如，Anchored Ridge 与普通 Ridge 的 MAE 差值区间为 $[-0.149, +0.091]$ ℃，包含零，说明本次比较尚不足以确定哪个模型的平均误差更低。

相邻预测窗口每隔 1 h 开始，未来目标存在大量重叠。例如，预测长度为 192 h 时，一次预测覆盖第 1–192 h；96 h 后开始的另一次预测覆盖第 97–288 h。两次预测都包含第 97–192 h 的真实油温，其误差因此可能相关。实验采用的重采样块长为 96 个窗口；超过 96 h 的预测中，不同块之间仍可能包含共同目标，得到的区间可能偏窄，长预测中模型差异的判断需要考虑这一影响。

为分析系统性偏差，先计算每个预测步在所有测试窗口上的平均误差 $\bar{e}_h = N^{-1}\sum_i e_{i,h}$，再用剩余误差 $e_{i,h} - \bar{e}_h$ 计算 MSE 和 MAE。这个去偏指标使用测试集真实值，用于事后分析预测偏差。

3 统计基线

本文设置五种统计基线。全局均值基线使用训练集的油温均值作为预测值；持续性基线重复最后一个观测值；24 h 和 96 h 局部均值基线分别使用最近 24 h 和 96 h 的油温均值；日周期朴素基线按时间顺序重复最近 24 h 的观测序列。

图 2 展示了测试集首个窗口的预测结果。对各预测长度的全部有效测试窗口计算 MAE，全局均值基线的误差为 12.324–12.758 ℃，局部均值基线和持续性基线的误差为 1.820–2.601 ℃。96 h 预测中，24 h 局部均值基线的 MAE 为 1.820 ℃，略低于 96 h 局部均值基线；192 h 及更长预测中，96 h 局部均值基线的误差较低。24 h 局部均值基线因此作为后续锚定模型的参考基线。

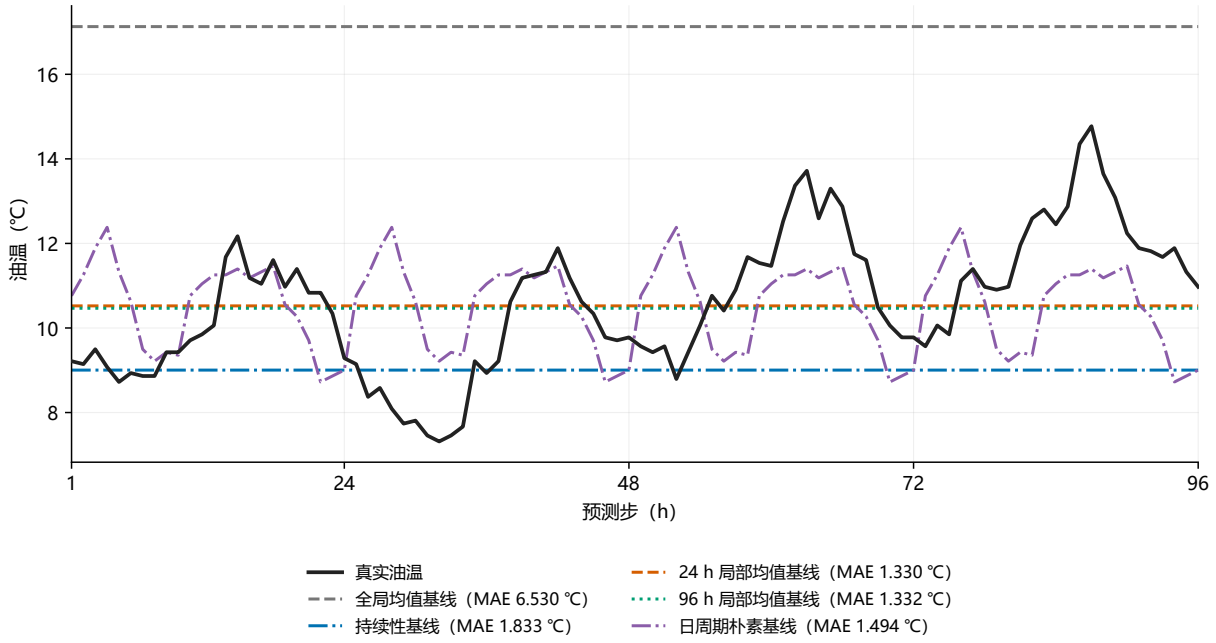


图 2: 测试集首个 96 h 预测窗口的真实油温与五种统计基线预测。图例中的 MAE 按该窗口的 96 个预测值计算。

4 从线性回归到局部水平锚定

24 h 局部均值基线在 96 h 任务上的 MAE 为 1.820 ℃，表明近期温度水平可为预测提供参考。这一基线将窗口内的观测压缩为一个均值，并在未来各时刻重复该值。历史窗口中不同时间的观测可能包含不同的预测信息，未来各时刻的变化也可能不同。线性回归为不同历史观测分配权重，并为每个未来时刻分别拟合预测关系。考虑到相邻小时的油温高度相关，采用带正则化的 Ridge 回归约束权重，先预测绝对温度，再分析其误差。

4.1 普通 Ridge 的水平偏差

Ridge（岭回归）在线性回归的平方误差中加入权重的二次惩罚，以约束系数大小。对 n 个训练窗口，将按各滞后位置的训练集均值和标准差变换后的历史油温组成矩阵 $X \in \mathbb{R}^{n\times 96}$，未来 96 h 的绝对油温组成矩阵 $Y \in \mathbb{R}^{n\times 96}$。普通多输出 Ridge 的权重 $A \in \mathbb{R}^{96\times 96}$ 和截距 $b \in \mathbb{R}^{96}$ 由下式求得：

$$\min_{A,b} \ \|Y - XA - \mathbf{1}_n b^{\top}\|_F^2 + \alpha\|A\|_F^2. \tag{3}$$

其中 α 控制正则化强度，截距不受惩罚。每个未来小时对应 A 的一列权重；对标准化历史向量 $\mathbf{x}_t$，预测结果为 $A^{\top}\mathbf{x}_t + b$，单位为摄氏度。模型直接输出整个未来窗口，正则化强度由验证集 MAE 选择。

验证集上 $\alpha = 10$ 最优，测试集 MSE 为 5.107、MAE 为 1.670 ℃、平均偏差为 +0.780 ℃。其 MAE 比 24 h 局部均值基线低 8.2%，平均偏差高于该基线的 +0.144 ℃。

普通 Ridge 的偏差随预测步单调增加：第 1–24 h 为 +0.317 ℃，第 73–96 h 达 +1.105 ℃（表 4）。训练段 OT 均值约为 17.13 ℃，测试段约为 4.85 ℃。普通 Ridge 的系数和接近 1，截距

随预测步从 0.04 增至 1.21；当输入来自较低水平的测试段时，模型仍把预测拉向训练段均值，因而在冬季高估。这一结果表明预测中存在随预测步增长的系统性偏移。

若按测试集每个预测步的真实平均误差扣除偏差（仅用于诊断），普通 Ridge 的 MSE 从 5.107 降至 4.400，MAE 从 1.670 降至 1.604；加入局部水平锚定后的 Ridge（下称 Anchored Ridge）去偏前后几乎不变（4.613 至 4.598，1.632 至 1.640）。去偏后普通 Ridge 的 MSE 低于 Anchored Ridge；原始误差的差异与两者的水平偏差有关。

验证集与测试集的差异也支持这一判断：验证集上普通 Ridge 的 MAE 为 2.229 ℃，略优于 Anchored Ridge 的 2.256 ℃；测试集上分别为 1.670 和 1.632 ℃。验证段处于夏秋、水平漂移较小，测试段进入冬季、漂移较大，锚定的收益主要在后者显现。

表 3: 96 h 输入、96 h 输出的水平诊断。去偏 MSE/MAE 按测试集每个预测步的真实平均误差扣除，仅用于区分水平误差与形状误差，不参与预测。

模型	MSE	MAE	平均偏差	去偏 MSE	去偏 MAE
普通 Ridge	5.107	1.670	+0.780	4.400	1.604
Anchored Ridge	4.613	1.632	+0.105	4.598	1.640
24 h 局部均值基线	5.454	1.820	+0.144	5.428	1.829

表 4: 测试集分段的平均偏差（℃）。各段对应预测步 1–24、25–48、49–72 和 73–96。

模型	1–24	25–48	49–72	73–96
普通 Ridge	+0.317	+0.737	+0.963	+1.105
Anchored Ridge	+0.030	+0.078	+0.131	+0.182
24 h 局部均值基线	+0.050	+0.107	+0.172	+0.248

4.2 参考水平与残差

上述偏差诊断表明，需要处理训练段与测试段的温度水平差异。为此，先从历史输入和预测目标中分离当前水平，再学习未来温度相对当前水平的变化。局部水平取最近 24 h 均值

$$\ell_t = \ell_t^{(24)} = \frac{1}{24}\sum_{i=0}^{23} y_{t-i}, \tag{4}$$

并构造

$$\mathbf{x}_t^c = \mathbf{x}_t - \ell_t \mathbf{1}_L, \qquad \mathbf{y}_t^c = \mathbf{y}_t - \ell_t \mathbf{1}_H. \tag{5}$$

训练时参考水平由输入计算，目标与输入减去同一数值；预测时模型生成未来相对该水平的偏移量，再加回 ℓ_t。图 3 将参考水平作为独立支路接入输出端，说明中心化输入和恢复水平使用同一历史统计量。

最后观测值对噪声敏感，96 h 均值更平滑但在快速变化时滞后；在 96 h 任务上，24 h 局部均值基线、持续性基线和 96 h 局部均值基线的 MAE 分别为 1.820、1.865 和 1.821 ℃。24 h 均值略优，因此作为主实验的参考；长预测中 96 h 均值略优，本文保留 24 h 以保持参考定义一致，并

在后文长预测实验中与统计基线比较。该锚定的零模型是 24 h 局部均值基线，Ridge 只学习相对偏移。

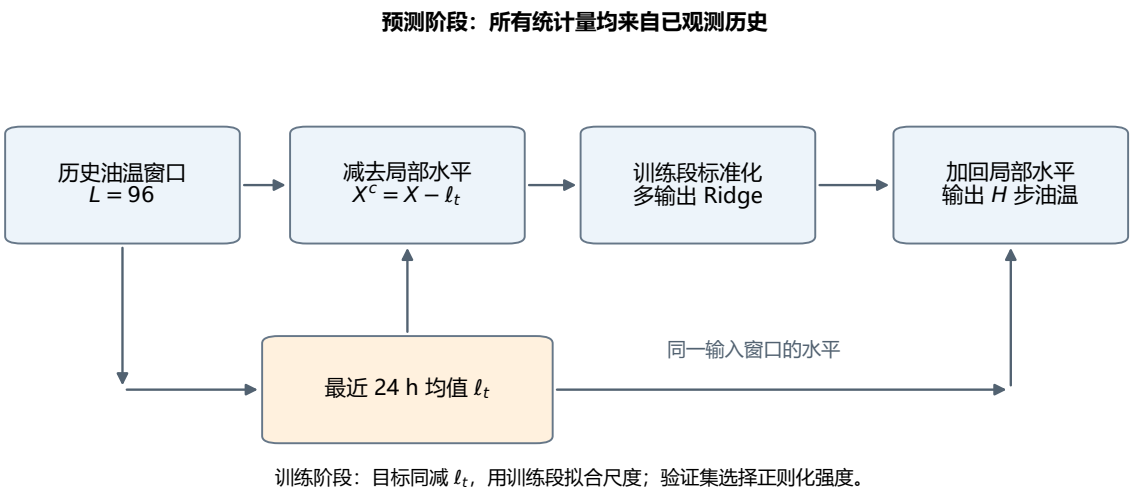


图 3: Anchored Ridge 的预测流程。历史输入分成残差建模与水平恢复两条支路。图中预测头输出油温残差；96 h 主实验的目标保留原单位，长预测实验则在头部输出后先完成目标反标准化。

4.3 多输出 Ridge 与正则化

Ridge 在最小二乘损失中加入系数的二次惩罚。多输出 Ridge 用同一历史窗口分别拟合各个未来小时的温度。对 n 个训练窗口，按滞后标准化后的输入矩阵记为 $Z \in \mathbb{R}^{n\times L}$，目标残差记为 $R \in \mathbb{R}^{n\times H}$。参数 $W \in \mathbb{R}^{L\times H}$ 与 $b \in \mathbb{R}^{H}$ 通过

$$\min_{W,b} \ \|R - ZW - \mathbf{1}_n b^\top\|_F^2 + \alpha\|W\|_F^2 \tag{6}$$

求解。截距不受惩罚；每个预测步有一组历史权重。预测为 $\hat{\mathbf{y}}_t = W^\top \mathbf{z}_t + b + \ell_t \mathbf{1}_H$，因此 96 h 历史到 96 h 输出含 $96 \times 96 + 96 = 9,312$ 个回归系数与截距。

直接多步预测为每个未来小时拟合一组权重，一次生成完整的预测序列。Anchored Ridge 的 α 候选值为 $\{0.1, 1, 10, 100, 1000\}$，验证 MAE 选中 $\alpha = 100$；0.1 到 100 的测试 MAE 差异小于 0.001 ℃，说明相对偏移中的可学信号较弱，强正则化把模型压向 24 h 局部均值基线，同时保留稳定的偏差修正。

若输入整体加上常数 c，局部均值也增加 c，中心化输入保持相同；固定标准化后的残差预测相同，最终输出增加 c。因此，该预测器对输入整体平移具有等变性。它显式保留当前水平，使线性映射主要拟合未来偏移量。当残差预测在原单位下为零时，模型退化为 24 h 局部均值基线；实际拟合的权重由训练损失与正则化决定。

4.4 线性模型比较与选择

普通 Ridge、Anchored Ridge 与 DLinear 的比较见表 6：普通 Ridge 的测试 MAE 为 1.670 ℃，Anchored Ridge 为 1.632 ℃，锚定 DLinear 的三种子均值为 1.635 ℃。Anchored Ridge 的平均偏差从普通 Ridge 的 +0.780 ℃ 降至 +0.105 ℃。

Anchored Ridge 相对普通 Ridge 的 MAE 仅降低 2.2%，MSE 降低 9.7%；两者 MAE 差值的 95% 区间包含零；相对 24 h 局部均值基线的 MAE 差为 -0.187 ℃，区间为 $[-0.294, -0.072]$ ℃，不跨零。因此，锚定模型相对局部均值基线的配对误差差异较明确；与普通 Ridge 的差异仍有不确定性。

DLinear 通过趋势分解实现类似水平处理：直接预测版本的 MAE 为 1.843 ℃，局部水平锚定版本为 1.635 ℃，与 Anchored Ridge 相差约 0.003 ℃。两种线性结构均可用于处理油温水平变化。Anchored Ridge 参数较少，求解过程确定，因此选为后续单模型参照，并在相同的水平锚定处理下比较非线性模型。

5 非线性模型的预测效果

第 4 节的结果表明，局部水平锚定降低了 Ridge 在测试集上的平均偏差。锚定后的模型通过历史温度相对于当前水平的变化，预测未来温度的相对偏移。为考察非线性结构能否更好地利用这些变化，本文比较 MLP、GRU、LSTM、PatchTST 与 SegRNN，并考察预测集成、预测长度、历史长度和片段交互的影响。各模型沿用相同的数据划分；主要对照使用 96 h 历史和 24 h 均值锚定，长历史实验使用 336 h 输入。

5.1 对照模型与输入

为比较不同模型的预测能力，各模型均直接生成完整预测向量。表中“直接预测”表示模型根据标准化历史油温预测未来油温，预测结果经反标准化后得到摄氏度；“局部水平锚定”表示输入和训练目标先减去该窗口最近 24 h 的油温均值，模型预测相对于该均值的变化，输出时再恢复该均值。两种方式均使用训练集确定标准化参数。表中“Ridge（局部水平锚定）”即前文的 Anchored Ridge。表 5 概括非线性模型的结构：除 SegRNN 使用 336 h 历史外，其余模型使用 96 h 历史；预测长度均为 96 h。PatchTST 按嵌入宽度区分为 16 维和 64 维两种配置。附录 A 展开各模型的结构细节。

表 5: 非线性对照模型的结构和参数量。

模型	从历史到未来的映射	参数量
MLP	两层 128 单元隐藏层，ReLU，直接输出	41,312
GRU	单层 64 维门控状态，末状态接线性头	19,104
LSTM	单层 64 维记忆与隐藏状态，接线性头	23,392
PatchTST 64 维	16 h 片段、8 h 步长、2 层编码	136,416
PatchTST 16 维	同一片段划分，3 层编码	24,112
SegRNN	48 h 分段，GRU 编码与并行预测	31,344

输入对照将单变量历史从 96 h 延长至 336 h。片段交互对照保留 16 维 PatchTST 的嵌入与预测头，以参数量接近的片段混合 MLP 替换自注意力。这些比较为最终输入和模型选择提供依据。

5.2 水平处理与预测误差

先在 96 h 输入、96 h 输出的条件下比较局部水平处理。持续性基线、24 h 局部均值基线和 96 h 局部均值基线的测试 MAE 分别为 1.865、1.820 和 1.821 ℃。24 h 局部均值基线的误差略低，作为锚定模型的参考；长预测实验还与 96 h 局部均值基线比较。表 6 给出各预测器的结果：神经模型报告三种子指标均值及样本标准差，偏差为三种子均值；16 维 PatchTST 与片段混合 MLP 仅运行锚定版本。MSE 单位为 $℃^2$，MAE 和偏差单位为 ℃。

表 6: S 模式下 96 h 输入、96 h 预测的测试结果。

模型	MSE	MAE	平均偏差
Ridge（直接预测）	5.107	1.670	+0.780
Ridge（局部水平锚定）	4.613	1.632	+0.105
MLP（直接预测）	12.198 ± 1.314	2.853 ± 0.186	+2.678
MLP（局部水平锚定）	4.680 ± 0.040	1.663 ± 0.006	−0.034
GRU（直接预测）	17.878 ± 1.040	3.532 ± 0.120	+3.331
GRU（局部水平锚定）	4.776 ± 0.208	1.671 ± 0.024	−0.030
LSTM（直接预测）	18.243 ± 0.031	3.565 ± 0.003	+3.339
LSTM（局部水平锚定）	5.077 ± 0.252	1.759 ± 0.044	−0.202
DLinear（直接预测）	6.224 ± 0.245	1.843 ± 0.036	+1.264
DLinear（局部水平锚定）	4.616 ± 0.004	1.635 ± 0.003	+0.093
PatchTST 64 维（直接预测）	11.250 ± 1.699	2.712 ± 0.262	+2.330
PatchTST 64 维（局部水平锚定）	4.777 ± 0.123	1.655 ± 0.035	+0.084
PatchTST 16 维（局部水平锚定）	4.842 ± 0.286	1.644 ± 0.034	+0.301
片段混合 MLP（局部水平锚定）	4.709 ± 0.028	1.684 ± 0.005	−0.010

直接预测的 MLP、GRU、LSTM 的 MAE 为 2.853、3.532、3.565 ℃。局部水平锚定后，它们分别降至 1.663、1.671、1.759 ℃。图 4(a) 展示锚定模型的测试 MAE，点表示三次训练的指标均值，横线表示样本标准差；Ridge 为一次确定性求解结果。各点均位于 24 h 局部均值基线虚线的左侧，说明这些模型的 MAE 均低于该基线。

图 4(b) 比较相同结构在两种水平处理下的平均预测偏差，正值表示预测偏高。MLP、GRU、LSTM 直接预测时的平均偏差分别为 +2.678、+3.331 和 +3.339 ℃；锚定后分别为 −0.034、−0.030 和 −0.202 ℃。64 维 PatchTST 的偏差也从 +2.330 ℃ 降至 +0.084 ℃。在该测试集上，局部水平锚定缩小了这些模型的平均偏差。

锚定后，16 维和 64 维 PatchTST 的三种子 MAE 均值分别为 1.644 和 1.655 ℃，高于 Anchored Ridge 的 1.632 ℃。这两组结果与线性模型较为接近，下面进一步考察多次训练的预测平均能否降低误差。

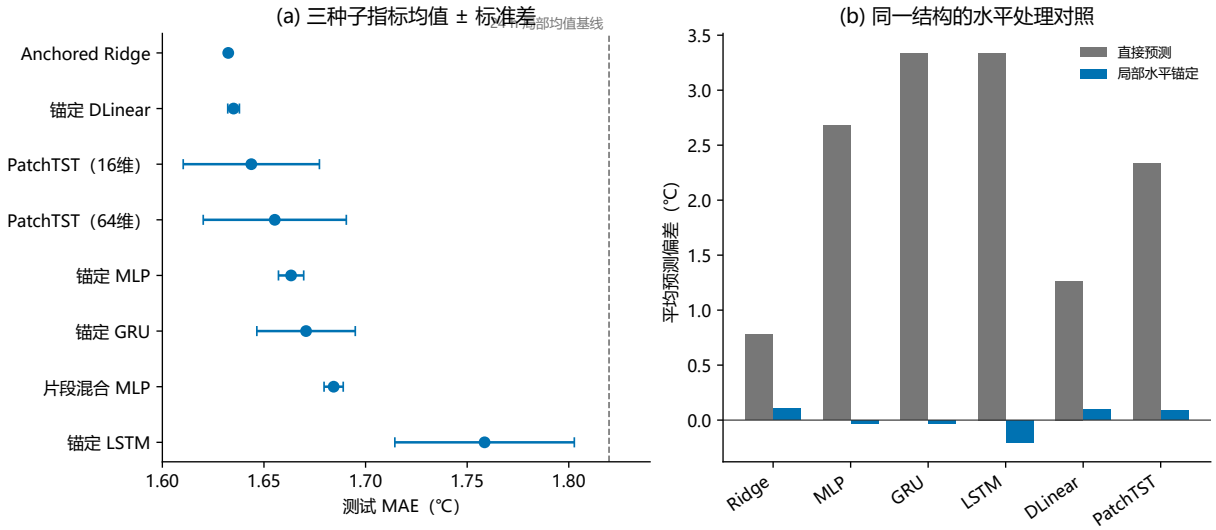


图 4: 96 h 预测的误差与偏差。(a) 点表示三种子 MAE 均值，误差线表示种子标准差，Ridge 为确定性结果；虚线为 24 h 局部均值基线。(b) 水平处理对照中的 PatchTST 采用 64 维、2 层配置。两图均使用 96 h 历史。

5.3 预测集成与归一化

对三个独立训练模型的预测取平均，可以考察预测集成对误差的影响。表 7 列出各模型的三种子指标均值和集成结果，模型均采用 96 h 历史和 24 h 均值锚定。指标均值由三次独立训练的误差取平均得到；集成结果则先逐点平均三个预测向量，再计算误差。16 维 PatchTST 集成的 MAE 为 1.600 ℃，低于 Anchored Ridge 的 1.632 ℃；锚定 GRU 集成的 MSE 为 4.525 $℃^2$，低于 Anchored Ridge 的 4.613 $℃^2$。

表 7: 三种子指标均值与预测集成结果。

	种子指标均值		预测集成	
模型	MSE	MAE	MSE	MAE
MLP	4.680	1.663	4.641	1.655
GRU	4.776	1.671	4.525	1.624
LSTM	5.077	1.759	4.864	1.722
DLinear	4.616	1.635	4.607	1.633
PatchTST 64 维	4.777	1.655	4.617	1.623
PatchTST 16 维	4.842	1.644	4.632	1.600
片段混合 MLP	4.709	1.684	4.585	1.660

除了使用 24 h 均值锚定，还对 64 维 PatchTST 考察了按窗口均值与标准差归一化的方式。对每个窗口计算 μ_t 和 $s_t = \mathrm{std}(\mathbf{x}_t) + 10^{-8}$，输入与目标均按这两个统计量变换，输出再乘 s_t 并加 μ_t。窗口归一化的三种子 MAE 为 1.669 ℃，24 h 均值锚定为 1.655 ℃；在该配置下，后者的平均误差低 0.014 ℃。

5.4 历史长度的影响

前述模型使用 96 h 历史；增加历史观测可能提供更长时间范围的温度信息。为考察输入长度的影响，保持预测长度为 96 h，将 Ridge 和 16 维 PatchTST 的历史长度从 96 h 延长至 336 h。Ridge 的 MAE 由 1.632 降至 1.625 ℃，配对差区间为 $[-0.152, +0.112]$ ℃，逐窗口胜率约 49.6%。PatchTST 的三种子 MAE 从 1.644 升至 1.758 ℃；预测集成从 1.600 升至 1.692 ℃，配对集成 MAE 差区间为 $[-0.070, +0.230]$ ℃。因此，这两组实验未表明延长历史能够降低预测误差。

延长历史也将 PatchTST 片段数从 11 增为 41，参数量从 24,112 增至 70,672。三个长历史模型均在第 1 轮取得最低验证 MAE；此后验证误差连续 20 轮未达到新的最低值，训练按早停规则结束。该结果同时涉及更长输入、更宽展平预测头和较少训练窗口，因此后续长历史比较需控制预测头容量。

5.5 注意力与片段循环

历史长度改变了 PatchTST 的片段数量，片段之间的信息如何交互也可能影响预测。为考察这一因素，在 96 h 历史设置下将自注意力替换为片段混合 MLP。替换后，三种子 MAE 均值从 1.644 增至 1.684 ℃，MSE 从 4.842 降至 4.709。两个预测集成的配对 MAE 差为 +0.059 ℃，95% 区间为 $[-0.041, +0.142]$ ℃；MSE 差为 −0.047，区间同样跨零。因此，该 11 片段小模型中，两种交互方式在现有测试窗口上的差异仍有较大不确定性。

片段混合 MLP 的种子 MAE 标准差为 0.005 ℃，自注意力模型为 0.034 ℃。替换自注意力后，三次训练之间的 MAE 波动减小，但平均 MAE 上升、平均 MSE 下降；两种预测集成的误差差值区间均跨零。现有结果显示，两种交互方式各有不同的误差表现，尚不足以确定替换带来一致的预测改进。

另一种片段模型 SegRNN 以循环状态传递片段信息。参考水平用于从输入和训练目标中减去当前温度水平，使模型学习相对变化；预测时再加回该水平，以恢复未来油温。实验比较最近 24 h 均值与最后观测值两种参考，考察参考水平的选择对 SegRNN 误差的影响。采用 336 h 历史时，两种设置的三种子 MAE 分别为 1.788 ± 0.049 和 1.694 ± 0.021 ℃。对应预测集成的 MAE 为 1.779 和 1.687 ℃，后者降低 0.092 ℃；按测试窗口计算的集成 MAE 配对差区间为 $[+0.060, +0.120]$ ℃。同样使用 336 h 历史的 Anchored Ridge 的 MAE 为 1.625 ℃，比调整后的 SegRNN 三种子指标均值低 0.069 ℃，比其预测集成低 0.062 ℃。因此，在本次测试中，Anchored Ridge 的预测误差更低。

5.6 小结

在 96 h 预测中，MLP、GRU、LSTM 和 PatchTST 经水平锚定后的误差降至与线性模型相近的范围。所比较的锚定神经模型，其三种子 MAE 均值均高于 Anchored Ridge 的 1.632 ℃。16 维 PatchTST 的三模型集成 MAE 为 1.600 ℃，GRU 集成的 MSE 为 4.525 $℃^2$，表明多次训练后的预测平均可以降低误差。历史长度和自注意力替换的对照尚未提供明确的误差降低证据。结合误差和模型数量，选用 Anchored Ridge 作为单模型方案。

6 不同预测长度的效果

模型比较完成后，进一步评估 Anchored Ridge 对不同预测长度的适用情况。为考察更长预测区间，保持历史长度 $L = 96$，对每个预测长度 H 独立拟合 Ridge，并以验证 MAE 选择正则化强度；四个长度均选中 $\alpha = 100$。表 8 使用各长度的全部有效测试窗口，MAE 改善率以同长度的 96 h 局部均值基线为参考。336 h 和 720 h 仅比较 Ridge 与统计基线。192 h 还比较了锚定 PatchTST，其三种子 MAE 为 1.993 ℃、集成 MAE 为 1.935 ℃，Ridge 为 1.914 ℃。

表 8： 96 h 历史下不同预测长度的结果。

H	窗口数	Ridge MSE	Ridge MAE	基线 MAE	MAE 改善率
96	2785	4.613	1.632	1.821	10.37%
192	2689	6.178	1.914	2.063	7.23%
336	2545	7.310	2.129	2.275	6.43%
720	2161	7.092	2.116	2.395	11.65%

预测长度增大时，有效起点数从 2,785 降至 2,161，因此表中跨行差异同时包含目标长度和起点集合变化。图 5(a) 在相同的 2,161 个起点上比较各预测长度，每个长度独立拟合模型，并计算整个预测区间的平均 MAE。Ridge MAE 随 H 从 96 增至 720，依次为 1.594、1.892、2.072、2.116 ℃。在共同起点下，336 h 至 720 h 的平均误差仍增加，但增幅较前两个区间小。

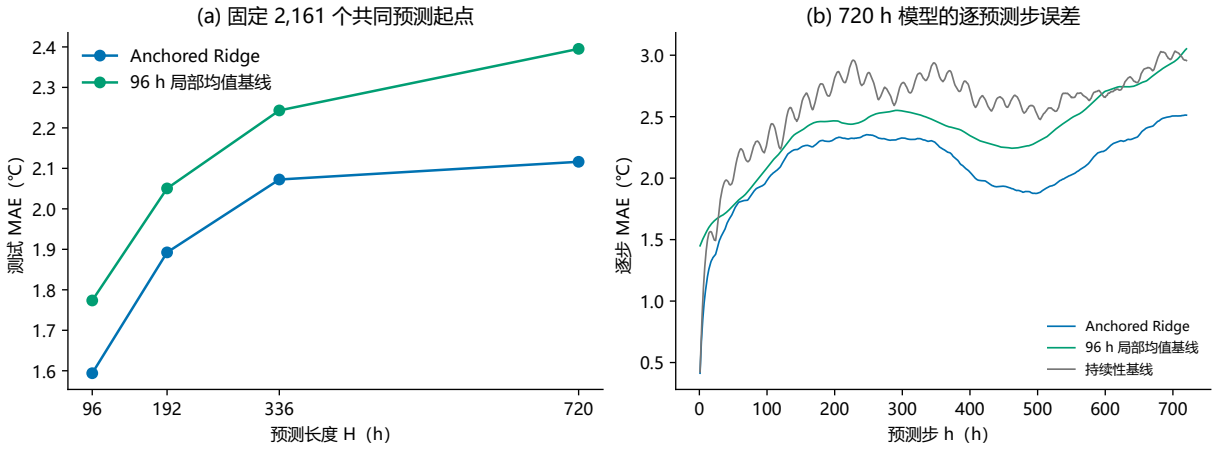


图 5： 不同预测长度的平均误差与 720 h 预测的逐步误差。

图 5(b) 固定 720 h 预测模型，分别计算未来第 h 小时的 MAE，以观察误差随预测步的变化。图中的持续性基线将预测起点前最后一次观测到的油温用于整个预测区间。720 h 模型的平均偏差为 +0.604 ℃，逐步误差也随预测步波动，说明远期预测仍存在水平偏差。综合各预测长度的结果，以 96 h 历史为输入的 Anchored Ridge 可用于生成长达 720 h 的油温预测，但使用远期预测时应考虑误差增大和水平偏差的问题。

7 讨论

7.1 线性模型为何具有竞争力

训练段油温在相邻时刻变化较平缓，1 h 和 24 h 滞后自相关分别为 0.994 和 0.940。近期观测因此包含较多关于未来温度的信息，96 h 历史窗口的线性加权已经能够利用其中一部分规律。这为线性模型在该任务中取得较低误差提供了一种可能的解释。

温度水平的变化也是模型表现的重要因素。训练段与测试段油温均值分别约为 17.13 ℃ 和 4.85 ℃；普通 Ridge 的测试平均偏差为 +0.780 ℃，局部水平锚定后降至 +0.105 ℃。MLP、GRU 和 LSTM 同样在锚定后降低了误差。这些结果表明，利用最近 24 h 的均值恢复当前水平，有助于处理不同时间段的温度水平差异。锚定后的神经网络单模型在测试 MAE 上仍高于 Anchored Ridge，说明在本次比较中，线性模型已经能够较好地利用处理后的历史信息。

较简单的映射还可能减少估计复杂关系的需求。Anchored Ridge 通过二次正则化约束历史权重，96 h 输入和输出共需 9,312 个回归系数与截距；在当前数据和训练设置下，这一映射已取得 1.632 ℃ 的 MAE。Huang 等在多个时间序列基准上发现，经过输入处理和参数调整的 Ridge 能与多种非线性模型竞争 [10]。虽然两项研究的变量与实验设置不同，但都表明线性预测器的表现与输入处理和模型配置有关。

7.2 结果的适用范围

本文使用固定的训练、验证和测试时间段，测试段主要覆盖晚秋至冬季。模型在其他季节的表现还需要使用不同时间段的数据检验。测试段有 3 天油温记录保持不变，实验保留了这些记录；后续可分别计算包含和排除这些日期时的误差，检查它们对结果的影响。

本研究在 96 h 预测中比较了多种模型；336 h 和 720 h 预测主要与统计基线比较。对神经网络的比较采用三个随机种子和有限的模型配置，长历史 PatchTST 同时增加了预测头参数量。后续可在相同预测头规模下比较不同历史长度，并在其他数据上检验最终模型。

8 结论

本文构建了用于预测变压器油温的 Anchored Ridge 模型：以最近 96 h 油温为输入，减去最近 24 h 的均值，使用验证集选出的 $\alpha = 100$ 拟合多输出 Ridge，并在输出端恢复局部温度水平，得到未来 96 h 的油温预测。

该模型在测试集上的 MSE 为 4.613 $℃^2$、MAE 为 1.632 ℃，相对 24 h 局部均值基线降低 10.3%。模型共有 9,312 个回归系数与截距，求解过程确定。

图 6 展示两个按日期预先确定的预测窗口。模型以预测起点之前的油温为输入，给出未来 96 h 的温度曲线；与保持固定水平的 24 h 局部均值基线相比，预测曲线体现了模型对未来温度变化的估计。

保持 96 h 输入并分别拟合更长预测区间时，192、336 和 720 h 的测试 MAE 分别为 1.914、2.129 和 2.116 ℃。该预测器仅使用历史油温，通过局部水平锚定与线性映射生成未来温度序列，为不同预测长度下的变压器油温预测提供了具体方案。

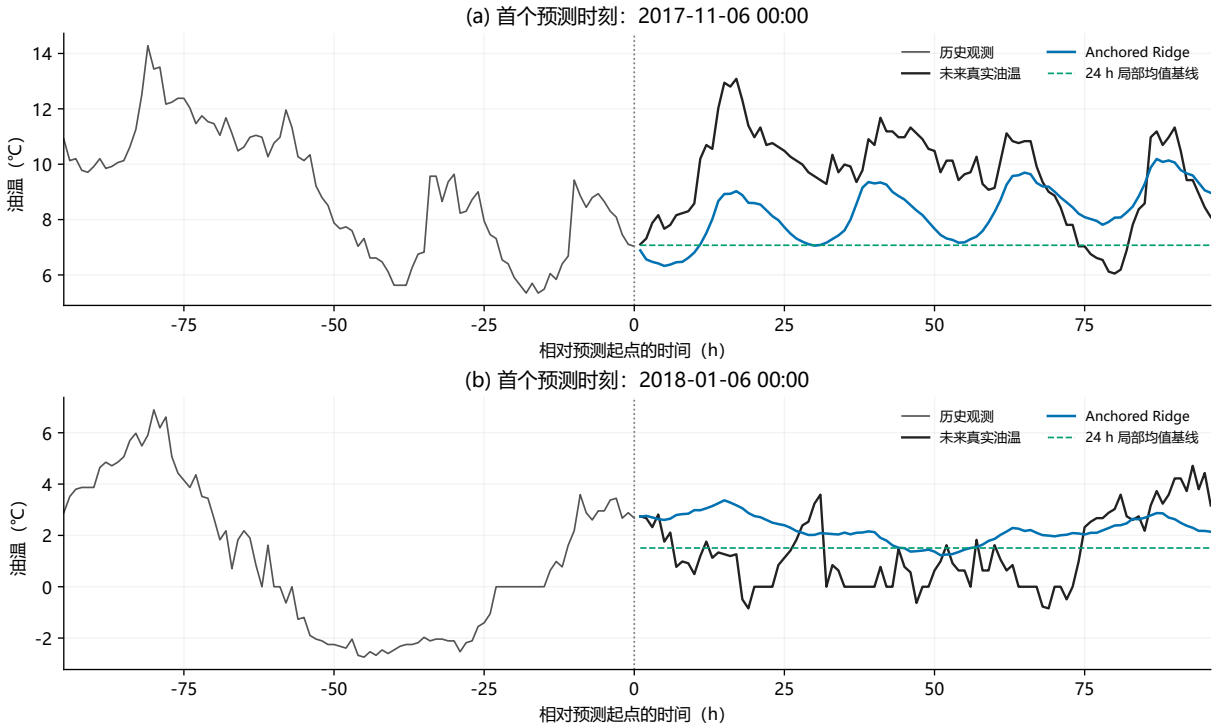


图 6: Anchored Ridge 的 96 h 油温预测示例。

参考文献

[1] JIMÉNEZ-NAVARRO M J, MARTÍNEZ-BALLESTEROS M, MARTÍNEZ-ÁLVAREZ F, et al. A new deep learning architecture with inductive bias balance for transformer oil temperature forecasting [J/OL]. Journal of Big Data, 2023, 10(1). DOI: 10.1186/s40537-023-00745-0.

[2] ZHOU H, ZHANG S, PENG J, et al. Informer: beyond efficient transformer for long sequence time-series forecasting[C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 11106-11115. DOI: 10.1609/aaai.v35i12.17325.

[3] ZHOU H, ZHANG S, PENG J, et al. ETDataset: electricity transformer dataset[EB/OL]. 2021. https://github.com/zhouhaoyi/ETDataset.

[4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C/OL]// Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37. 2023: 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[5] NIE Y, NGUYEN N H, SINTHONG P, et al. A time series is worth 64 words: long-term forecasting with transformers[C]//International Conference on Learning Representations (ICLR). 2023.

[6] WU H, XU J, WANG J, et al. Autoformer: decomposition transformers with auto-correlation for long-term series forecasting[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021.

[7] ZHOU T, MA Z, WEN Q, et al. FEDformer: frequency enhanced decomposed transformer for long-term series forecasting[C]//Proceedings of Machine Learning Research: Vol. 162 Proceedings of the 39th International Conference on Machine Learning (ICML). 2022.

[8] LIN S, LIN W, WU W, et al. SegRNN: segment recurrent neural network for long-term time series forecasting[A/OL]. arXiv (2023). https://arxiv.org/abs/2308.11200.

[9] KIM T, KIM J, TAE Y, et al. Reversible instance normalization for accurate time-series forecasting against distribution shift[C/OL]//International Conference on Learning Representations (ICLR). 2022. https://openreview.net/forum?id=cGDAkQo1C0p.

[10] HUANG L, XU J, DARLOW L. How good can linear models be for time-series forecasting?[A/OL]. arXiv (2026). https://arxiv.org/abs/2606.27282.

[11] HAN L, YE H J, ZHAN D C. The capacity and robustness trade-off: revisiting the channel independent strategy for multivariate time series forecasting[A/OL]. arXiv (2023). https://arxiv.org/abs/2304.05206.

[12] THUML Group. Time-Series-Library: a library for deep time series analysis[EB/OL]. 2024. https://github.com/thuml/Time-Series-Library.

A 对照模型的结构细节

A.1 感知机与循环网络

MLP 对整个窗口进行非线性映射，循环网络则按时间顺序更新状态。多层感知机（Multilayer Perceptron, MLP）采用两层 128 单元隐藏层：

$$h_1 = \mathrm{ReLU}(A_1 z + a_1), \quad h_2 = \mathrm{ReLU}(A_2 h_1 + a_2), \quad \hat{r} = A_3 h_2 + a_3. \tag{7}$$

默认尺寸依次为 $96 \to 128 \to 128 \to 96$，共 41,312 个参数。模型将整个窗口作为向量输入，直接学习历史位置之间的非线性组合。

门控循环单元（Gated Recurrent Unit, GRU）与长短期记忆网络（Long Short-Term Memory, LSTM）按小时顺序接收标量输入，均为单层、隐藏宽度 64。GRU 利用重置门和更新门控制历史状态，例如

$$r_j = \sigma(A_r x_j + U_r h_{j-1} + b_r), \quad z_j = \sigma(A_z x_j + U_z h_{j-1} + b_z), \quad h_j = (1 - z_j) \odot \tilde{h}_j + z_j \odot h_{j-1}, \tag{8}$$

其中 σ 为 sigmoid 函数，$\odot$ 表示逐元素乘积。候选状态为

$$\tilde{h}_j = \tanh(A_n x_j + a_n + r_j \odot (U_n h_{j-1} + b_n)). \tag{9}$$

更新门控制候选状态与前一时刻状态的比例，因此 GRU 可在逐小时编码中保留较慢变化的信息。

LSTM 另外维护记忆单元 c_j。令输入门、遗忘门、输出门分别为 i_j, f_j, o_j，各门均对当前输入与上一隐藏状态的仿射变换使用 sigmoid。候选记忆 g_j 则使用双曲正切函数，状态更新为

$$c_j = f_j \odot c_{j-1} + i_j \odot g_j, \qquad h_j = o_j \odot \tanh(c_j). \tag{10}$$

两种循环网络均从零初始状态编码历史，取最后隐藏状态 $h_L \in \mathbb{R}^{64}$，接 $64 \to H$ 线性头。GRU 与 LSTM 分别含 19,104 和 23,392 个参数，作为两种门控状态设计的对照。

循环计算发生在历史编码阶段，输出端一次生成 H 个值。直接预测版本在标准化空间预测油温；局部水平锚定版本在式 (5) 的残差空间预测，再加回参考水平。这样可在相同循环结构内部检查水平处理对误差的作用。

A.2 分解线性模型

DLinear 对平滑趋势与短时残差分别预测，再合并两个分支。先对标准化输入做宽度 25、步长 1 的移动平均，在两端各重复边界值 12 次以保持长度。令该线性平滑算子为 M，则趋势 $T = Mz$，剩余项 $S = z - T$，预测为

$$\hat{r} = A_T T + a_T + A_S S + a_S. \tag{11}$$

两个线性头均为 $96 \to 96$，总参数量为 18,624。两支输出逐步相加后反标准化；局部水平锚定版本再加回参考水平，得到摄氏度下的油温预测。

移动平均与两个预测头均为线性或仿射映射，因此式 (11) 可写成 $[A_T M + A_S(I - M)]z + a_T + a_S$。该模型与 Ridge 都通过仿射映射预测未来温度，但参数化和训练方式不同。两者的映射形式可能是测试误差接近的原因之一。

A.3 片段 Transformer

PatchTST 将相邻小时组织为连续片段，以片段作为注意力输入 [5]。将标准化序列按长度 $P = 16$、步长 $S = 8$ 切成重叠片段，片段数为

$$N_p = \left\lfloor \frac{L - P}{S} \right\rfloor + 1. \tag{12}$$

$L = 96$ 时得到 11 个片段，$L = 336$ 时得到 41 个片段。模型仅使用完整片段；每个片段经 $16 \to d$ 线性嵌入并加可学习位置向量。输入张量从 $B \times L$ 变为 $B \times N_p \times d$，其中 B 为批量大小。

每个编码块使用前置层归一化。令输入为 U，则

$$V = U + \mathrm{Dropout}(\mathrm{MHA}(\mathrm{LN}(U))), \tag{13}$$

$$U^{+} = V + \mathrm{Dropout}(\mathrm{FFN}(\mathrm{LN}(V))). \tag{14}$$

多头自注意力（Multi-Head Attention, MHA）使用 4 个头；单头以 $\mathrm{softmax}(QK^{\top}/\sqrt{d_k})V_h$ 聚合片段表示。前馈网络（Feed-Forward Network, FFN）为 $d \to d_{\mathrm{ff}} \to d$，使用 GELU 激活。Dropout 在训练时随机屏蔽部分神经元输出。编码后展平所有片段，接 dropout 和 $N_p d \to H$ 线性头，完成直接多步预测。

图 7(a) 给出片段编码到预测头的连接，表 9 区分实验使用的配置。64 维、2 层模型用于直接预测、局部水平锚定与窗口均值尺度归一化比较，并用于 192 h 预测；16 维、3 层模型用于注意力消融和长历史比较。两组配置在本文始终按嵌入宽度标记，分别对应独立的模型与结果。

A.4 片段交互替换

片段交互对照比较内容相关的注意力权重与固定参数映射。保留 16 维 PatchTST 的嵌入、位置编码、三层深度、前馈网络和预测头，将自注意力替换为跨片段 MLP。对 $B \times 11 \times 16$ 的归一化表示，先转置为 $B \times 16 \times 11$，沿片段轴应用 $11 \to 48 \to 11$ 的 GELU 网络，再转置回原形状并残差相加。

该模型各特征共享片段混合映射，dropout 为 0.1，其余训练设置沿用注意力版本。替换后的总参数量为 24,193，比注意力版本多 81，约为 0.34%。因此，这组实验在近似相同容量下比较内容相关注意力与固定参数片段映射，结果用于判断该小配置的片段交互需求。

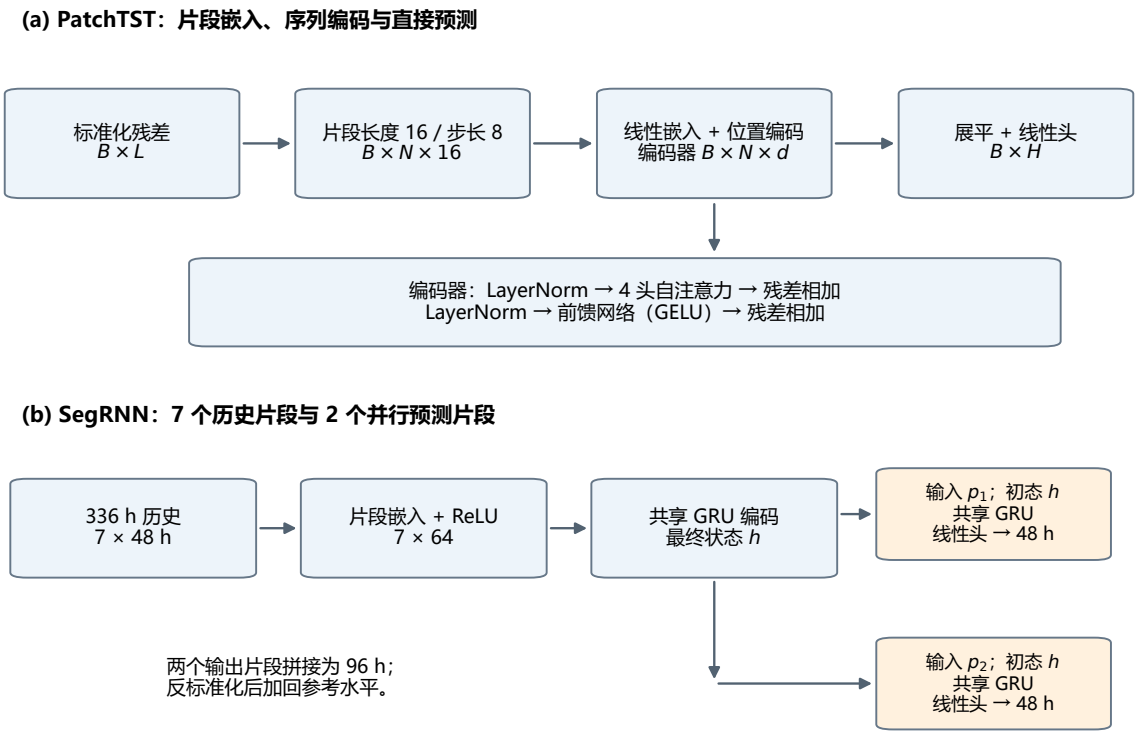


图 7: 两类片段模型的结构。PatchTST 沿片段序列编码，张量尺寸随历史长度变化；SegRNN 将 7 个历史片段压缩为状态，再以两个位置向量并行生成未来片段。两种结构均在输出端恢复输入窗口的参考水平。

表 9: PatchTST 实际配置。各配置均为 4 头注意力，编码与预测头 dropout 均为 0.1。参数量包含嵌入、位置向量、编码块和输出头。

L	H	d	层数	d_{ff}	参数量	用途
96	96	64	2	128	136,416	水平处理比较
96	192	64	2	128	204,096	长预测比较
96	96	16	3	32	24,112	片段交互对照
336	96	16	3	32	70,672	历史长度比较

A.5 片段循环网络

SegRNN 在片段之间更新循环状态，并行生成多个未来片段 [8]。输入为 336 h，按 48 h 划为 7 个非重叠片段。每段经 $48 \to 64$ 线性层和 ReLU 转为 64 维表示，单层 GRU 依次处理 7 段，得到最终状态 $h \in \mathbb{R}^{64}$。

未来 96 h 分成两个 48 h 片段。解码时把同一状态 h 复制给两个分支，每个分支使用独立的可学习位置向量 $p_j \in \mathbb{R}^{64}$ 作为单步 GRU 输入；编码与解码共享 GRU 参数。两个解码状态分别经过 dropout 与 $64 \to 48$ 的线性头，再拼接为 96 维输出。图 7(b) 展示这两个并行分支，共含 31,344 个参数。

SegRNN 比较两种参考水平：最近 24 h 均值，以及最后观测值。后者按 $x - y_t$ 和 $Y - y_t$ 构造残差；两种版本均以训练窗口拟合固定尺度。它们用相同结构检验参考水平与分段循环预测之间的关系。

B 完整代码

本文的完整代码见 GitHub 仓库：`https://github.com/The-time-forever/ETTh1`。