越复杂越好？

基于 ETTh1 的油温单变量长序列预测研究

匿名作者

代码、数据与实验记录随文附上

摘要

长序列时序预测（LSTF）研究近年来不断引入更复杂的网络结构，但在真实工业场景中，模型复杂度是否必然带来更高精度仍缺乏系统证据。本文以 ETTh1 电力变压器油温（OT）预测为对象，在 S 模式（仅使用历史 OT）与官方 12/4/4 划分下，系统比较了统计基线、线性模型、MLP、GRU、LSTM、DLinear、PatchTST 与 SegRNN 等十余种方法，并考察了预测长度、负载输入、历史长度和自注意力机制的影响。结果表明：不进行水平处理时，复杂模型在冬季测试集上因分布漂移产生 0.78–3.34 ℃ 的系统偏差，原始误差甚至劣于简单基线；引入最近 24 h 均值锚定后，各模型迅速收敛到相近水平，简单的 Anchored Ridge 在 96/192/336/720 步上均保持最优或并列最优（96 步 MAE 1.632 ℃，720 步 2.116 ℃）。负载输入、更长历史与自注意力均未带来稳定增益；远期误差在 336 步后饱和，局部水平基线成为强对照。本文最终给出一个简单、可解释、易部署的油温预测方案，并说明在 ETTh1 上 “更复杂” 并不等于 “更准确”。

关键词： 长序列时序预测；油温预测；ETTh1；线性模型；水平锚定；基准评测；通道独立

Abstract

Long-term time-series forecasting (LSTF) has seen a rapid growth in model complexity, yet whether such complexity translates into accuracy in practical industrial settings remains unclear. Using the ETTh1 transformer oil-temperature (OT) dataset, we conduct a controlled univariate (S-mode) study under the official 12/4/4 split. We compare statistical baselines, linear models, MLPs, GRUs, LSTMs, DLinear, PatchTST, and SegRNN, and examine the effects of forecast horizon, load inputs, look-back length, and self-attention. Without level handling, complex models exhibit systematic biases of 0.78–3.34 ℃ on the winter test set and can be worse than simple baselines. A 24-hour local-level anchor removes most of this bias; with anchoring, a simple Anchored Ridge is the best or tied-best model at 96/192/336/720 steps (MAE 1.632 ℃ at 96 and 2.116 ℃ at 720). Load inputs, longer history, and self-attention provide no robust gain, and errors saturate beyond 336 steps. We conclude with a simple, interpretable, deployment-ready OT forecasting recipe, and show that more complexity is not necessarily better on ETTh1.

Keywords: long-term time-series forecasting; oil temperature forecasting; ETTh1; linear model; level anchoring; benchmark; channel independence

1 引言

电力变压器油温（Oil Temperature, OT）是反映设备热状态与负载能力的关键变量。准确的日前至数周油温预测，可用于越限预警、动态负载调度与检修计划制定。与一般时序预测任务相比，油温序列具有显著的年周期、较强的热惯性和明显的年际水平漂移；在实际系统中，往往只能获得 OT 自身的历史记录，而负载、环境温度等外生变量并不总是可用。因此，仅依赖 *OT* 历史的单变量长序列预测，是一个既有现实意义、又便于控制变量的研究场景。ETTh1 正是这一场景下最常用的公开基准：它由 Informer 作者收集并随论文发布，包含中国某省两个变压器 2016–2018 年的小时级记录 [1, 2]。

近年来，LSTF 的方法演进呈现出明显的复杂化趋势。Informer 以稀疏注意力和生成式解码器降低了长序列建模的计算代价 [1]；Autoformer 引入序列分解与自相关机制 [3]；FEDformer 在频域进行低秩增强 [4]；Pyraformer 使用金字塔式注意力 [5]；Crossformer 进一步建模变量之间的跨维依赖 [6]；PatchTST 将序列切分为 patch 并用自注意力学习片段关系 [7]；iTransformer 则将变量维作为 token[8]；TimesNet 通过周期折叠把一维序列转为二维变化建模 [9]。这些工作不断刷新基准精度，也在无形中强化了一个假设：结构越复杂，预测越准确。

然而，另一条研究线索给出了相反的提示。Zeng 等在 “Are Transformers Effective for Time Series Forecasting?” 中系统指出，简单的线性模型（DLinear）在多个长序列基准上可以持平甚至超过复杂的 Transformer[10]；TiDE 用稠密编码器与线性解码器取得了有竞争力的结果 [11]；TSMixer 以全 MLP 结构在多变量预测中表现强健 [12]；N-HiTS 通过多速率采样与分层插值改进了长 horizon 预测 [13]；N-BEATS 则展示了纯 MLP 基函数展开的有效性 [14]。与此同时，RevIN 表明，一个简单的可逆实例归一化就能显著缓解分布漂移带来的误差 [15]；PatchTST 与后续的通道独立（channel independent, CI）研究也指出，通道独立策略在鲁棒性上往往优于通道混合 [7, 16]。这些结果共同说明：性能提升未必来自更复杂的 *token mixing*，而可能来自水平处理、归一化或通道独立等更简单的归纳偏置。

在上述两条线索之间，S 模式（仅使用目标变量自身的历史，输入与输出均为单变量）提供了一个理想的 “去混淆” 视角。Time-Series-Library 等统一评测框架将 S 模式与多变量 M、MS 模式并列，DLinear、PatchTST 等论文也报告了单变量或通道独立的设置 [7, 10, 17]。S 模式剥离了负载、天气等外生变量和跨通道混合的影响，使我们能够直接回答一个更基础的问题：在只有 *OT* 历史的情况下，增加模型复杂度是否真的有用？对 ETTh1 而言，这个问题尤其尖锐：OT 的年周期与年际水平漂移很强，而官方 12/4/4 划分的测试集恰好落在冬季，训练集与测试集之间存在明显的分布偏移。若模型不能处理这种水平变化，再复杂的结构也可能被系统性偏差淹没。

现有比较往往同时改变了多个因素：模型结构、输入变量（S/M/MS）、历史长度、预测长度、归一化方式与训练预算。由此得到的 “复杂模型更好” 或 “线性模型更好” 的结论，难以归因到单一机制。尤其是，负载输入是否提供增量信息、更长历史是否被有效利用、自注意力是否不可替代这三个问题，在 ETTh1 的 S 模式下仍缺乏系统的、可复现的证据。本文不提出新的网络结构，而是以受控实验回答这些问题，并给出一个可直接部署的油温预测方案。

本文的主要贡献如下：

- 在 ETTh1 的 S 模式与官方 12/4/4 划分下，构建了一个覆盖统计基线、线性模型、MLP、GRU、LSTM、DLinear、PatchTST、SegRNN 等十余种方法的受控基准，统一了输入/输

出、标准化、alpha/早停与评价协议。

- 识别出**局部水平锚定**是决定性能的关键机制：将输入与目标同时减去最近 24 h 的 OT 均值，可消除 0.78–3.34 ℃ 的系统偏差，并使线性模型获得平移等变性；未锚定的复杂模型在冬季测试集上显著退化。
- 证明在 ETTh1 上，简单的 Anchored Ridge 在 96/192/336/720 步上均保持最优或并列最优；负载输入、更长历史与自注意力均未带来稳定增益，而 DLinear 的趋势分解与水平锚定在功能上是替代关系。
- 给出面向 OT 预测的最终方案、可复现的实验协议与失败模式分析，说明“更复杂”并不等于“更准确”，并为后续引入天气等外生变量提供基线。

2 相关工作

2.1 长序列预测与 ETTh1 基准

ETTh1 随 Informer 发布，包含 17,420 条小时级记录（2016-07-01 至 2018-06-26），字段为高/中/低三档有用/无用负荷与油温 OT[1, 2]。Informer 之后，Autoformer、FEDformer、Pyraformer、Crossformer 等工作均将其作为标准长序列基准，并沿用 12/4/4 个月的训练/验证/测试划分 [3–6]。PatchTST 与 iTransformer 分别从 patch 表示和变量维注意力两个方向推进了这一基准 [7, 8]；TimesNet 则将其纳入通用时序分析框架 [9]。Time-Series-Library 统一了这些模型的数据管道与评测协议，使 S/M/MS 三种模式可以在同一套划分下比较 [17]。

2.2 模型家族

Transformer 家族以自注意力为核心，通过稀疏化、分解、频域增强、跨维建模、patch 化或变量维反转等机制扩展长序列建模能力 [1, 3–9]。**循环网络**以 GRU/LSTM 为代表；SegRNN 将序列切分为固定长度 segment，用 GRU 编码历史 segment，并以 parallel multi-step 方式解码未来 segment，以降低长 horizon 的误差累积 [18]。**CNN/MLP 家族**包括 SCINet 的样本卷积与交互 [19]、TSMixer 的时间/通道混合 [12]、N-HiTS 的多速率分层插值 [13] 与 N-BEATS 的基函数展开 [14]。**线性家族**以 DLinear 为代表，将序列分解为趋势与季节项后分别做线性映射 [10]；TiDE 则用稠密编码器与线性解码器处理协变量 [11]。

2.3 归一化、通道独立与 S 模式

分布漂移是时序预测的核心难点之一。RevIN 通过对每个输入窗口做可逆实例归一化，在归一化空间预测后再恢复均值与方差，显著提升了非平稳序列的精度 [15]。PatchTST 采用通道独立策略，将每个变量单独建模，避免了跨通道混合带来的过拟合 [7]；Han 等进一步从容量与鲁棒性的权衡角度解释了 CI 策略的有效性 [16]。S 模式可以看作通道独立思想在“单目标”场景下的极端形式：输入与输出都只包含 OT，因而完全排除了负载与跨通道信息的干扰。本文沿用这一设置，以回答“仅凭 OT 历史，复杂度是否值得”的问题。

2.4 本文定位

本文不是新的架构论文，而是一项受控的实证研究。与 DLinear、PatchTST、RevIN 等工作相比，我们的区别在于：在同一 S 模式协议下，同时比较统计基线、线性、循环、卷积/MLP 与 Transformer 家族，并把“水平锚定”作为一个显式的、可解释的机制单独考察；同时通过负载输入、历史长度与注意力消融，区分“输入信息”“模型容量”与“token mixing 机制”的贡献。最终，我们将结论落到一个可部署的 OT 预测方案，而不是停留在基准排名。

3 问题定义与实验协议

3.1 数据与 S 模式

ETTh1 包含 17,420 条小时级记录，时间范围为 2016-07-01 00:00 至 2018-06-26 19:00，字段为 `HUFL`，`HULL`，`MUFL`，`MULL`，`LUFL`，`LULL`，`OT`。本文只使用 OT 作为输入与输出（S 模式）：

$$\mathbf{x}_t = (y_{t-95}, \ldots, y_t) \in \mathbb{R}^{96}, \qquad \mathbf{y}_t = (y_{t+1}, \ldots, y_{t+96}) \in \mathbb{R}^{96}, \tag{1}$$

其中 y_t 为 t 时刻的 OT。模型直接输出 96 步（direct multi-step），不做递归解码。

3.2 划分与评价

我们严格采用官方 12/4/4 划分：训练、验证、测试分别使用前 12、4、4 个“30 天月”，对应行索引 $[0, 8640)$、$[8640, 11520)$、$[11520, 14400)$；验证/测试的输入窗口包含前一段末尾的 96 行 lookback，因此目标块仍为 2,880 行。标准协议只使用前 14,400 行，末尾 3,020 行不参与。测试集覆盖 2017-10-24 至 2018-02-20，只有冬季，这是本文解释结果时必须考虑的背景。

评价指标为反归一化后的 MSE 与 MAE。为便于比较，我们同时报告：

- **skill**：$\text{skill} = 1 - \text{MSE}_{\text{model}}/\text{MSE}_{\text{base}}$（或 MAE 版本），基线与 B1（最后值）或 B2b（最近 96 h 均值）比较；
- **bias**：预测误差的均值，用于诊断水平漂移；
- **步内去偏误差**：先减去每个预测步的均值误差，再计算 MSE/MAE，用于区分“水平错误”与“形状错误”；
- **block bootstrap**：以 96 为块长、2,000 次重采样，报告配对 MAE/MSE 差的 95% 置信区间与逐窗口胜率。

神经网络均使用 3 个随机种子（0/1/2），报告均值与标准差；线性模型的 alpha 与神经网络的早停轮次均在验证集上选择，测试集不参与模型选择。实验在单张 RTX 5090 Laptop GPU（24 GB）上完成，PyTorch 2.14.1，CUDA 13.0。

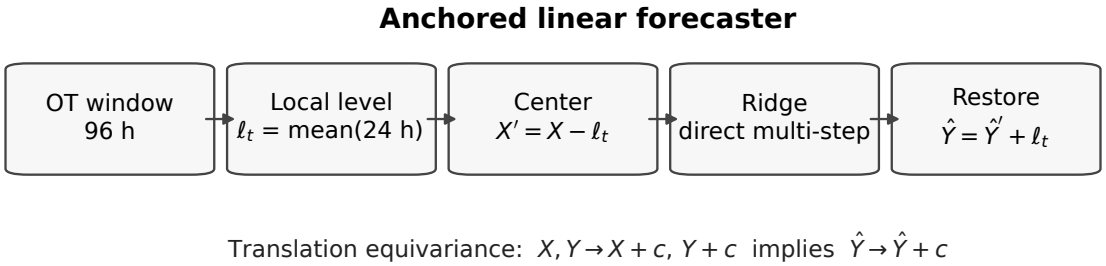


图 1: Anchored Ridge 的预测流程。输入窗口先由最近 24 h 的均值给出局部水平 ℓ_t，输入与目标同时中心化后由 Ridge 直接输出 96 步，最后加回 ℓ_t。该结构对输入/目标的共同平移严格等变。

4 方法

4.1 局部水平锚定的线性预测器

整体流程如图 1 所示。设输入窗口为 $\mathbf{x}_t = (y_{t-95}, \ldots, y_t)$，目标为 $\mathbf{y}_t = (y_{t+1}, \ldots, y_{t+96})$。定义最近 24 h 的局部水平

$$\ell_t = \frac{1}{24} \sum_{i=0}^{23} y_{t-i}. \tag{2}$$

将输入与目标同时中心化：

$$\mathbf{x}'_t = \mathbf{x}_t - \ell_t \mathbf{1}, \qquad \mathbf{y}'_t = \mathbf{y}_t - \ell_t \mathbf{1}. \tag{3}$$

在中心化空间训练 Ridge 回归：

$$\hat{\mathbf{y}}'_t = \mathbf{W}\mathbf{x}'_t + \mathbf{b}, \qquad \hat{\mathbf{y}}_t = \hat{\mathbf{y}}'_t + \ell_t. \tag{4}$$

输入按滞后维标准化、目标按预测步标准化，标准化统计量只在训练集拟合；正则化强度 $\alpha \in \{0.1, 1, 10, 100, 1000\}$ 由验证集 MAE 选择。该模型有两个关键性质：

1. **平移等变**：若输入与目标同时平移 c，即 $\mathbf{x} \to \mathbf{x} + c$、$\mathbf{y} \to \mathbf{y} + c$，则 $\ell_t \to \ell_t + c$、$\mathbf{x}' \to \mathbf{x}'$，从而 $\hat{\mathbf{y}} \to \hat{\mathbf{y}} + c$。模型无需重新学习绝对温度水平。
2. **零系数极限是 B2a**：当 $\mathbf{W} = 0, \mathbf{b} = 0$ 时，$\hat{\mathbf{y}}_t = \ell_t \mathbf{1}$，即“最近 24 h 均值”基线。因此 Anchored Ridge 是在强基线之上的安全修正，而不是一个可能显著劣于基线的黑箱。

本文的“锚定”是一种轻量、无参数的实例级水平处理；它与 RevIN 的“减均值、除标准差”思路相近，但只去除水平、不缩放方差，更适合 S 模式下 OT 的缓慢热惯性 [15]。

4.2 统计基线

B1（persistence）用最后观测值重复 96 步；B2a 用最近 24 h 均值重复 96 步；B2b 用最近 96 h 均值重复 96 步；B3（seasonal naive）重复最后 24 h 的模式。B2a 是 Anchored Ridge 的零系数极限；B2b 是长 horizon 下最强的局部水平基线。

4.3 神经对照模型

为覆盖主要模型家族，我们比较：MLP（96–128–128–96，ReLU）、GRU（hidden 64）、LSTM（hidden 64）、DLinear（kernel 25 的移动平均分解 + 两个线性头）、PatchTST（patch 16/stride 8、d_model 16、4 heads、3 层）与 SegRNN（seg_len 48、7 个历史 segment、2 个预测 segment、GRU、parallel multi-step）。每个模型都有 *plain*（直接预测绝对 OT）与 *anchored*（使用式 (2)–(3)）两个版本；plain 版本用于检验“不做水平处理时复杂度是否仍有用”，anchored 版本用于与 Anchored Ridge 公平比较。所有神经网络使用 MSE 损失、Adam（学习率 10^{-3}、权重衰减 10^{-4}）、batch 256、梯度裁剪 1.0、验证集 MAE 早停（patience 20，最多 300 epoch），并训练 3 个种子。

4.4 评价逻辑

本文的核心不是“哪个模型在排行榜上高一位”，而是三个可检验的问题：

1. **水平处理**是否解释了复杂模型与简单模型的主要差异？
2. 在锚定之后，**模型复杂度**是否仍带来稳定增益？
3. **负载输入、历史长度与自注意力**是否提供了独立于锚定的增量信息？

我们通过 bias/去偏误差、跨 horizon 的 skill、S vs MS、L=96 vs L=336、Attention vs token mixing 等对照逐一回答。

5 实验结果与分析

5.1 S 模式 96→96：复杂度阶梯

表 1 给出 S 模式 96→96 的主要结果。统计基线中，B2b 最强（MAE 1.821），但仍明显弱于线性模型。**Anchored Ridge 取得最低 MAE（1.632）与最低 MSE（4.613）**；Anchored DLinear（1.635）、PatchTST small（1.644）、Anchored MLP（1.663）与 Anchored GRU（1.671）紧随其后，差距均在 0.04 ℃ 以内。

图 2a 将锚定模型按 MAE 排列。可以看到，模型家族之间的差距远小于“是否锚定”带来的差距：plain MLP/GRU/LSTM 的 MAE 分别为 2.853/3.532/3.565，远差于 B2b；加上锚定后分别降到 1.663/1.671/1.759，立刻回到 Anchored Ridge 附近。这一模式在 DLinear 与 PatchTST 上同样成立。可见，*在 ETTh1 的 S 模式下，水平处理比模型结构更重要。*

5.2 为什么锚定有效：偏差与形状

图 2b 给出 plain 与 anchored 版本的总体 bias。plain MLP/GRU/LSTM 的 bias 分别达到 +2.68/+3.33/+3.34 ℃，plain DLinear 与 plain PatchTST 也有 +1.26/+2.33 ℃；这意味着它们在冬季测试集上系统性高估。原因是训练集 OT 均值为 17.13 ℃，而测试集只有 4.85 ℃；不做水平处理的模型会把训练段的绝对水平带入测试段。锚定后，各家族的 bias 降到 −0.20 至 +0.11 ℃，其中 Anchored Ridge 为 +0.105 ℃，Anchored DLinear 为 +0.093 ℃。

表 1: S 模式 96→96 的主要结果。MSE/MAE 单位为 ℃^{2}/℃；神经模型为 3 个种子的均值；bias 为预测误差均值；“—” 表示该基线未单独统计 bias。

模型	MSE	MAE	bias
B1 persistence	5.833	1.865	+0.122
B2a local mean 24	5.454	1.820	+0.144
B2b local mean 96	5.617	1.821	—
Plain Ridge	5.107	1.670	+0.781
Anchored Ridge	**4.613**	**1.632**	+0.105
Plain MLP	12.198	2.853	+2.678
Anchored MLP	4.680	1.663	−0.034
Plain GRU	17.878	3.532	+3.331
Anchored GRU	4.776	1.671	−0.030
Plain LSTM	18.243	3.565	+3.339
Anchored LSTM	5.077	1.759	−0.202
Plain DLinear	6.225	1.843	+1.264
Anchored DLinear	4.616	1.635	+0.093
PatchTST small (anchored)	4.842	1.644	+0.301
SegRNN last-value	4.614	1.694	−0.415
No-Attention (token mixing)	4.709	1.684	−0.010

去偏误差进一步支持这一解释：plain DLinear 的步内去偏 MSE 为 4.307，其实优于 plain Ridge 的 4.400，说明趋势分解确实改善了 “形状”；但其 bias 为 +1.264，导致原始 MSE 仍高达 6.225。Anchored DLinear 修掉水平后，原始 MSE 降到 4.616，与 Anchored Ridge 的 4.613 基本一致。换言之，**DLinear 的 trend 分解与 24 h 水平锚定在功能上是替代关系，而非互补关系**：两者都在处理水平/趋势，锚定之后分解的增量价值消失。

Anchored Ridge 对 B2a 的配对 MAE 差为 −0.187 ℃ (95% CI $[-0.294, -0.072]$)，MSE 差为 −0.842 ($[-1.368, -0.252]$)，逐窗口胜率 62.3%；相对 B2b 的 MAE 优势为 0.189 ℃ (skill 10.4%)。这些差异虽不算大，但在 2,785 个测试窗口上稳定存在。

5.3 预测长度：误差饱和与局部水平基线

表 2 与图 3 给出 Anchored Ridge 在 H=96/192/336/720 上的表现。绝对误差从 96 步的 1.632 ℃ 上升到 336 步的 2.129 ℃，随后在 720 步反而略降到 2.116 ℃；相对 B2b 的 MAE skill 则从 10.4% 降到 6.4%，再在 720 步回升到 11.7%。这一非单调现象并非模型在 720 步突然变强，而是因为：

- Anchored Ridge 的绝对误差在 336 步后饱和；
- B2b（最近 96 h 均值）在 30 天 horizon 上明显变旧，bias 从 0.55 ℃ 增至 1.37 ℃；
- 因此相对 skill 回升。

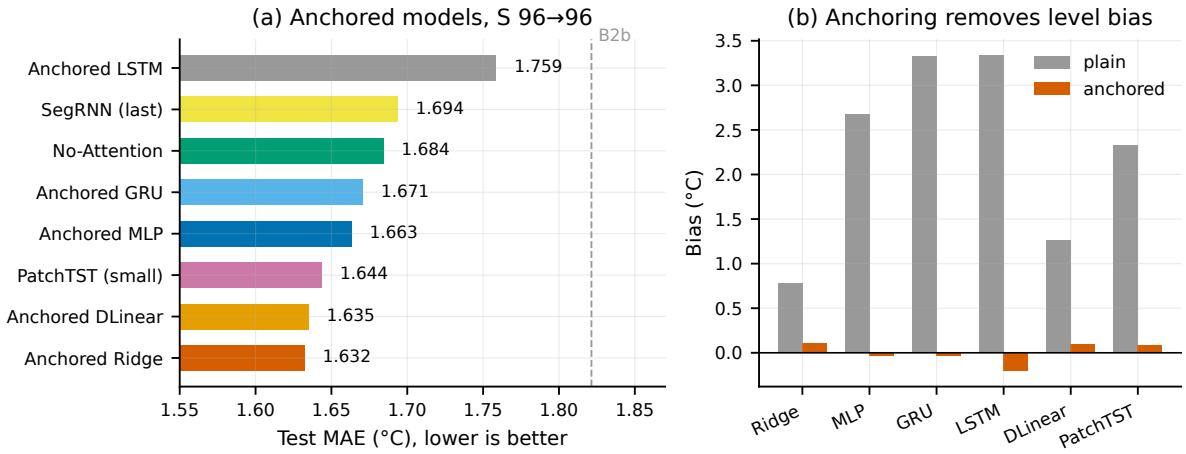


图 2: (a) 锚定模型的测试 MAE；虚线为 B2b 局部水平基线。(b) plain 与 anchored 版本的总体 bias；水平锚定几乎消除了所有家族的正偏差。

表 2: Anchored Ridge 的跨 horizon 结果。MAE/MSE 单位为 ℃/℃^{2}；skill 为相对 B2b 的 MAE 提升。

Horizon	Ridge MSE	Ridge MAE	B1 MAE	B2b MAE	MAE skill	MSE skill
96	4.613	1.632	1.865	1.821	10.37%	17.88%
192	6.178	1.914	2.163	2.063	7.23%	12.08%
336	7.310	2.129	2.434	2.275	6.43%	11.02%
720	7.092	2.116	2.601	2.395	11.65%	22.93%

分段分析显示，Ridge 相对 B2b 的优势高度集中在 1–24 步：在 H=336 上，1–24 步的 MAE skill 为 31.2%，25–336 步只有约 5%；在 H=720 上，1–24 步为 29.4%，337–720 步回升到 15.0%，因为基线的水平已经过期。换句话说，*Anchored Ridge* 的主要价值是“把当前水平校准好，并对未来几天给出温和修正”；超过约 96 h 后，B2b 已经捕获了大部分可预测信号。

5.4 消融：负载、历史长度与注意力

表 3 与图 4 汇总了三组消融。

负载输入。将输入从 96 个 OT 扩展为 96×7 的负荷 +OT 后，MS 的 MAE 从 1.633 升到 1.795，MSE 从 4.614 升到 5.412，配对 MAE 差为 +0.163（95% CI [+0.113, +0.226]），逐窗口胜率仅 27.9%。MS 模型确实给 HULL/MULL 等通道分配了非零系数，但性能没有提升，说明这些关系不迁移；这与 EDA 中“负荷–OT 相关跨期变号、HUFL–MUFL 与 HULL–MULL 强共线”的观察一致。负载通道不是“越多越好”的信息源。

历史长度。将输入从 96 h 延长到 336 h：Anchored Ridge 的 MAE 从 1.632 微降到 1.625，MSE 从 4.613 降到 4.468，配对 CI 仍跨 0，胜率 49.6%，只是很小的、不显著的改善；而 PatchTST 的 MAE 从 1.644 升到 1.758，MSE 从 4.842 升到 4.996，且 336 h 版本在 epoch 1 就早停——额外历史带来的是更大的 head 与更严重的过拟合，而不是更多可用信号。

注意力。用一个参数量接近的 token-mixing MLP（24,193 vs 24,112 参数）替换自注意力，MAE 从 1.644 变为 1.684（mean）、从 1.600 变为 1.660（ensemble），MSE 反而略好；配对 MAE

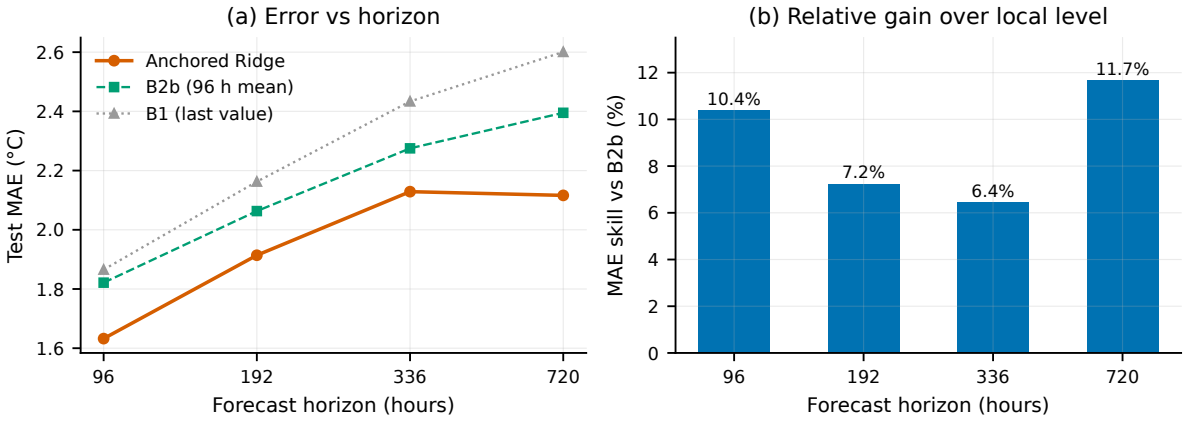


图 3: (a) Anchored Ridge 与 B1/B2b 的测试 MAE 随 horizon 的变化；(b) 相对 B2b 的 MAE skill。误差在 336 步后饱和，而局部水平基线继续变差，导致 720 步的相对 skill 回升。

表 3: 关键消融。除特别说明外均为 S 模式 96→96；数值为测试 MAE（℃）。

实验	设置	MAE	对照 MAE
负载输入	S (OT only)	1.633	—
	MS (7 channels)	1.795	1.633
历史长度	Ridge, L=96	1.632	—
	Ridge, L=336	1.625	1.632
	PatchTST, L=96	1.644	—
	PatchTST, L=336	1.758	1.644
注意力	Attention (mean / ensemble)	1.644 / 1.600	—
	Token mixing (mean / ensemble)	1.684 / 1.660	1.644 / 1.600
趋势分解	DLinear plain	1.843	—
	DLinear anchored	1.635	1.632 (Ridge)

差 +0.059 (CI $[-0.041, +0.142]$), 胜率 44.6%。没有证据表明自注意力在该任务中不可替代；token mixing 甚至更稳定（seed 标准差更小）。

5.5 最终方案

综合以上结果，本文推荐的 OT 预测方案是 **Anchored Ridge**：

1. 取最近 96 h 的 OT 作为输入，最近 24 h 的均值作为局部水平 ℓ_t；
2. 对输入与目标同时减去 ℓ_t，按滞后/预测步用训练集统计量标准化；
3. 在训练集上拟合多输出 Ridge，$\alpha = 100$（验证集 MAE 选择），直接输出 96 步；
4. 预测时加回 ℓ_t；若需 192/336/720 步，仅调整输出层并重新拟合，锚定与标准化流程不变。

该方案在 96/192/336/720 步上的 MAE 分别为 1.632/1.914/2.129/2.116 ℃，均优于 B1 与 B2b；

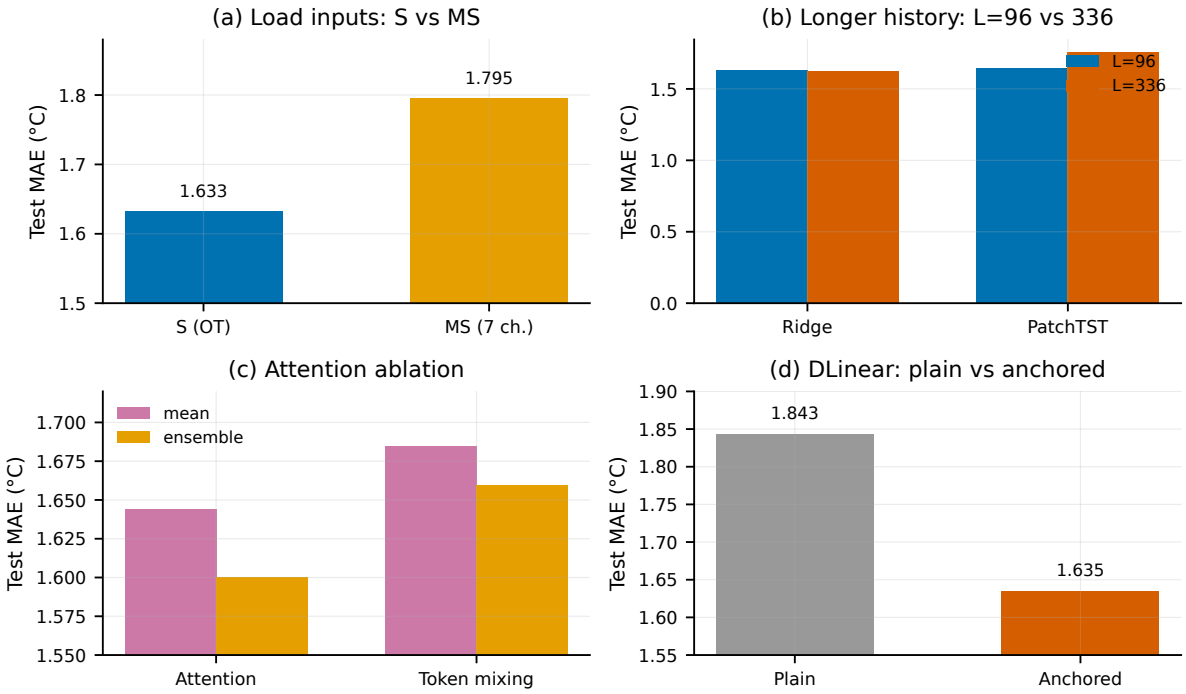


图 4: 四组消融：(a) 加入 6 个负载通道（MS）反而变差；(b) 更长历史对 Ridge 只有微小改善，对 PatchTST 反而变差；(c) 用参数匹配的 token-mixing MLP 替换自注意力，性能没有明显下降；(d) DLinear 的趋势分解只有在水平锚定后才能追平 Anchored Ridge。

在 96 步上比最强的神经模型（PatchTST small，1.644）低约 0.012 ℃，且参数量与推理成本低一个数量级。它不需要 GPU，不需要早停与随机种子，部署时只需保存 **W**、**b**、标准化统计量与 24 h 均值。对于“只有 OT 历史”的场景，这是一个稳健、可解释、易维护的默认方案。

6 讨论

6.1 为什么复杂度没有带来收益

本文的结果可以由三个因素解释。第一，**水平漂移主导误差**：训练集 OT 均值 17.13 ℃，测试集 4.85 ℃，且测试集只有冬季；不做水平处理的模型会把训练段的绝对水平带入测试段，产生 0.78–3.34 ℃ 的偏差。这个偏差远大于模型结构带来的差异。第二，**S 模式的可学信号有限**：OT 的年周期解释 81% 的方差，日周期只再解释 5.7%，周周期 2.3%；在只有 OT 历史的情况下，模型能学到的“形状”信息本就不多，复杂结构的边际收益很容易被噪声与过拟合抵消。第三，**数据规模小**：训练集只有 8,449 个 96 h 窗口；PatchTST 等模型在 1–10 个 epoch 内就开始过拟合，参数量更大的模型反而更脆弱。

这也解释了为什么 DLinear 的趋势分解与 24 h 锚定是替代关系：两者都在处理水平/趋势；锚定把水平拿掉后，分解的增量价值消失。同理，负载输入的 MS 实验没有带来增益，因为负荷–OT 的相关性跨期不稳定，模型学到的更多是季节混杂而非可迁移的因果信号。注意力消融则说明，在当前小模型与低信号任务上，token mixing 足以达到与自注意力相当的性能。

6.2 与已有工作的关系

本文的结论与 DLinear 的“简单线性模型可以很强”一致 [10]，但进一步指出：在 ETTh1 的 S 模式下，线性模型之所以强，很大程度上是因为它更容易与水平锚定结合；plain Ridge 的 MAE 仍有 1.670，而 Anchored Ridge 降到 1.632。与 RevIN 的实例归一化相比 [15]，24 h 均值锚定更轻量，只处理水平、不处理方差；在 OT 这种热惯性强的序列上已经足够。与 PatchTST 的通道独立策略相比 [7, 16]，本文的 S 模式可以看作其单变量极限；我们的结果表明，通道独立的价值在 ETTh1 上主要体现在“避免负载噪声”，而不是“让 Transformer 更强”。SegRNN 的 last-value 归一化优于我们移植的 24 h 锚定，也说明归一化方式与网络结构存在交互，不能简单地把线性模型的锚定直接搬到所有模型上 [18]。TiDE、TSMixer、N-HiTS 等简单/稠密模型在其它基准上的成功 [11–13]，与本文“复杂度不是关键”的判断方向一致。

6.3 局限与有效性威胁

本文有三类局限。第一，**单一数据集、单一划分**：所有结论基于 ETTh1 与官方 12/4/4；测试集只有冬季，无法代表全年。第二，**外生变量缺失**：我们没有环境温度/天气数据；OT 的主要驱动因素可能不在数据集中，因此绝对误差（约 1.6–2.1 ℃）不能完全归因于模型。第三，**神经模型未穷尽调参**：我们采用统一、轻量的配置与早停，未对每个模型做大规模超参搜索；更大的模型或不同的正则化可能改变小数点后的排序。此外，ETTh1 存在月末冻结、2016-12 负荷停机等采集伪影；本文未做掩码，但这些伪影在 S 模式的 OT 序列上主要影响少量窗口，且不改变“锚定优于不锚定、简单优于复杂”的主要结论。最后，本文只做点预测，未评估区间/概率预测；长 horizon 的不确定性可能比点误差的微小差异更重要。

7 结论

本文以 ETTh1 油温预测为对象，在 S 模式与官方 12/4/4 划分下系统比较了统计基线、线性模型、MLP、GRU、LSTM、DLinear、PatchTST 与 SegRNN 等十余种方法，并考察了预测长度、负载输入、历史长度与自注意力的影响。结果表明：不进行水平处理时，复杂模型会因分布漂移产生严重偏差，甚至劣于简单基线；引入最近 24 h 均值锚定后，各模型收敛到相近水平，简单的 Anchored Ridge 在 96/192/336/720 步上均保持最优或并列最优（MAE 1.632/1.914/2.129/2.116 ℃）。负载输入、更长历史与自注意力均未带来稳定增益；远期误差在 336 步后饱和，局部水平基线成为强对照。本文最终给出一个简单、可解释、易部署的 OT 预测方案，并说明在 ETTh1 上“更复杂”并不等于“更准确”。未来工作将引入环境温度等外生变量，并在概率预测与更多数据集上检验本文结论的外部有效性。

参考文献

[1] ZHOU H, ZHANG S, PENG J, et al. Informer: beyond efficient transformer for long sequence time-series forecasting[C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 11106-11115. DOI: 10.1609/aaai.v35i12.17325.

[2] ZHOU H, ZHANG S, PENG J, et al. ETDataset: electricity transformer dataset[EB/OL]. 2021. https://github.com/zhouhaoyi/ETDataset.

[3] WU H, XU J, WANG J, et al. Autoformer: decomposition transformers with auto-correlation for long-term series forecasting[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021.

[4] ZHOU T, MA Z, WEN Q, et al. FEDformer: frequency enhanced decomposed transformer for long-term series forecasting[C]//Proceedings of Machine Learning Research: Vol. 162 Proceedings of the 39th International Conference on Machine Learning (ICML). 2022.

[5] LIU S, YU H, LIAO C, et al. Pyraformer: low-complexity pyramidal attention for long-range time series modeling and forecasting[C]//International Conference on Learning Representations (ICLR). 2022.

[6] ZHANG Y, YAN J. Crossformer: transformer utilizing cross-dimension dependency for multivariate time series forecasting[C]//International Conference on Learning Representations (ICLR). 2023.

[7] NIE Y, NGUYEN N H, SINTHONG P, et al. A time series is worth 64 words: long-term forecasting with transformers[C]//International Conference on Learning Representations (ICLR). 2023.

[8] LIU Y, HU T, ZHANG H, et al. iTransformer: inverted transformers are effective for time series forecasting[C]//International Conference on Learning Representations (ICLR). 2024.

[9] WU H, HU T, LIU Y, et al. TimesNet: temporal 2D-variation modeling for general time series analysis[C]//International Conference on Learning Representations (ICLR). 2023.

[10] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting? [C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37. 2023: 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[11] DAS A, KONG W, LEACH A, et al. Long-term forecasting with TiDE: time-series dense encoder[A/OL]. arXiv (2023). https://arxiv.org/abs/2304.08424.

[12] EKAMBARAM V, JATI A, NGUYEN N, et al. TSMixer: lightweight MLP-mixer model for multivariate time series forecasting[C/OL]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD). 2023: 459-469. DOI: 10.1145/3580305.3599533.

[13] CHALLU C, OLIVARES K G, ORESHKIN B N, et al. NHITS: neural hierarchical interpolation for time series forecasting[C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37. 2023: 6989-6997. DOI: 10.1609/aaai.v37i6.25854.

[14] ORESHKIN B N, CARPOV D, CHAPADOS N, et al. N-BEATS: neural basis expansion analysis for interpretable time series forecasting[C]//International Conference on Learning Representations (ICLR). 2020.

[15] KIM T, KIM J, TAE Y, et al. Reversible instance normalization for accurate time-series forecasting against distribution shift[C/OL]//International Conference on Learning Representations (ICLR). 2022. https://openreview.net/forum?id=cGDAkQo1C0p.

[16] HAN L, YE H J, ZHAN D C. The capacity and robustness trade-off: revisiting the channel independent strategy for multivariate time series forecasting[A/OL]. arXiv (2023). https://arxiv.org/abs/2304.05206.

[17] THUML Group. Time-Series-Library: a library for deep time series analysis[EB/OL]. 2024. https://github.com/thuml/Time-Series-Library.

[18] LIN S, LIN W, WU W, et al. SegRNN: segment recurrent neural network for long-term time series forecasting[A/OL]. arXiv (2023). https://arxiv.org/abs/2308.11200.

[19] LIU M, ZENG A, CHEN M, et al. SCINet: time series modeling and forecasting with sample convolution and interaction[C]//Advances in Neural Information Processing Systems: Vol. 35. 2022: 5816-5828.