越复杂越好？

摘要

电力变压器油温预测需要根据已观测历史估计未来的温度水平与变化趋势。针对仅使用历史油温预测未来油温的单变量任务，在 ETTh1 小时级数据上构建并评估局部水平锚定 Ridge（岭回归，以下简称 Anchored Ridge）方案。该方案以最近 96 h 油温为输入，用最近 24 h 均值确定当前水平，用线性映射预测未来 96 h 的温度偏移，再加回局部水平。依据已有单变量预测、线性预测与实例归一化研究，比较多层感知机、循环网络、DLinear、PatchTST 和 SegRNN，并考察负载通道与历史长度。固定时间划分下，最终方案的测试均方误差为 4.613 ℃^{2}、平均绝对误差为 1.632 ℃；后者比 24 h 均值预测降低 10.3%，与锚定 DLinear 的 1.635 ℃ 接近。保持 96 h 历史，将预测长度扩展到 192、336、720 h 时，平均绝对误差分别为 1.914、2.129、2.116 ℃。实验表明，当前任务中局部温度水平的处理直接影响预测误差；在锚定残差上增加非线性结构没有带来稳定的单模型增益，集成可以降低方差，但需要多个网络和多次训练。最终形成由历史油温、局部水平估计和多输出 Ridge 组成的单模型预测方案，为 ETTh1 的单变量油温预测提供具体方法及其适用条件。

关键词：变压器油温；单变量预测；长序列预测；ETTh1；Ridge；局部水平锚定

Abstract

Transformer oil-temperature forecasting requires estimating future temperature levels and temporal variation from observed history. We develop and evaluate a local-level anchored Ridge predictor for the univariate ETTh1 task, using historical oil temperature as the sole input. The predictor takes a 96-hour window, estimates its local level from the latest 24 hours, directly forecasts future deviations, and restores the level to obtain a 96-hour temperature trajectory. Building on prior work on univariate forecasting, linear predictors, and instance normalization, we compare multilayer perceptrons, recurrent networks, DLinear, PatchTST, and SegRNN, with additional experiments on load channels and history length. Under a fixed chronological split, the selected predictor achieves a mean squared error of 4.613 degrees Celsius squared and a mean absolute error (MAE) of 1.632 degrees Celsius. Its MAE is 10.3% below the 24-hour mean baseline and close to the 1.635 achieved by anchored DLinear. With the same 96-hour input, extending the horizon to 192, 336, and 720 hours yields MAEs of 1.914, 2.129, and 2.116, respectively. Local-level handling directly affects forecasting error; adding nonlinear structure on the anchored residual does not yield a consistent single-model gain, and ensembling reduces variance only at the cost of multiple networks. The resulting single-model solution combines historical oil temperature, local-level estimation, and multi-output Ridge regression, with its applicability assessed on the ETTh1 split.

1 引言

电力变压器运行时，油温随负荷与热状态变化。根据历史观测估计未来油温，是研究温度变化预警和设备运行安排的基础。Jiménez-Navarro 等围绕变压器油温预测构建了平滑残差网络，并同时考察误差与模型规模，说明预测精度和求解成本需要共同考虑 [1]。本研究以油温（Oil Temperature, OT）为唯一预测目标，关注根据连续历史记录生成未来温度序列的具体方法。

电力变压器数据集（Electricity Transformer Dataset, ETT）由 Informer 工作发布，记录油温与六个负荷变量，其中 ETTh1 为小时级数据 [2, 3]。围绕 ETT 的预测任务，Informer 官方实现将单变量输入、单变量输出记为 S 模式，多变量输入、单变量输出记为 MS 模式[1]。本文采用 S 模式，只使用 OT 历史预测未来 OT；负荷通道作为补充实验，用于检验增加输入变量对当前方案的作用。

单变量油温预测已有明确的文献基础。Zeng 等在《Are Transformers Effective for Time Series Forecasting?》附录 C.1 中比较了 ETT 数据上的单变量长序列预测，并讨论了 ETTh1 训练段与测试段之间的分布变化 [4]。Nie 等在 PatchTST 论文附录 A.3 中明确将 ETT 的 oil temperature 作为单变量预测对象 [5]。这些研究为本文的 S 模式设置、预测长度和对照模型提供了直接依据。

在这一设置下，增加模型复杂度是否有助于降低油温误差，需要结合已有方法的机制判断。Informer、Autoformer 和 FEDformer 分别通过稀疏注意力、序列分解与频域计算处理长序列 [2, 6, 7]。Zeng 等同时展示了简单线性预测器的竞争力，并通过 NLinear 在预测前减去最后观测值、输出后加回该值，以减轻窗口间水平变化的影响 [4]。因而，线性预测和参考水平处理构成了本任务的直接起点。

片段模型提供了有代表性的结构对照。PatchTST 以局部片段作为输入单元，在单个通道内学习时间关系 [5]；SegRNN 通过片段级循环和并行多步预测压缩长序列计算 [8]。RevIN 则对每个输入窗口进行可逆的均值与尺度变换 [9]。Huang 等以 Ridge 为基础，在包括 ETTh1 的八个基准上搜索历史长度、局部归一化与正则化等设置，发现经过调节的线性模型能够与多种非线性模型竞争 [10]。这些研究为油温预测中的结构与预处理选择提供了依据。

ETTh1 中，历史温度水平是需要明确处理的信息。当前固定划分下，训练段约覆盖一年，测试段集中在晚秋至冬季，二者 OT 均值约为 17.13 ℃ 和 4.85 ℃。直接由历史映射未来绝对温度时，模型既要识别当前水平，又要学习未来变化。最近一天的油温均值能够提供局部参考，因此可将未来温度写成“当前局部水平加相对变化”，再由预测器学习相对变化。

基于上述研究，本文构建 Anchored Ridge 油温预测器：以最近 24 h 均值为参考，将 96 h 历史和未来目标同时中心化，学习历史残差到未来残差的线性映射。该方案沿用已有研究中的直接多步预测、参考水平恢复和线性建模思想，并针对 ETTh1 的 OT 任务组合这些处理。模型比较用于判断这一具体方案能否满足预测需要，以及更复杂结构能够带来多少额外误差变化。

本文的工作包括三个方面：一是明确 S 模式下的油温预测问题，构建从历史观测到未来温度序列的完整预测器；二是以统计预测、线性模型、循环网络和片段模型进行比较，分析水平处理与输入选择；三是给出最终预测方案，在 96 h 预测中取得 1.632 ℃ 的平均绝对误差，并评估其在更长预测区间上的表现。对于允许多个网络共同预测的设置，另行保留预测集成结果，以区分单模型方案与多模型方案的效果。

[1]任务标记见 Informer 官方实现的参数说明：`https://github.com/zhouhaoyi/Informer2020`。

2 相关工作

2.1 单变量油温预测

ETT 同时支持多变量预测与单变量油温预测，后者将一个目标变量的历史映射到其未来序列 [2, 5]。S 模式使输入信息与输出对象保持一致，适合研究历史 OT 本身能够支持的预测程度。本文以这一任务为主要范围，评价始终围绕未来 OT 的 MSE 与 MAE 展开。

通道独立策略也提供了相关依据。Han 等将多变量序列拆成独立通道建模，分析了模型容量与分布变化下预测鲁棒性的关系 [11]。单个 OT 的 S 模式与多通道共享参数的通道独立模型在训练信息上有所区别：前者只接触 OT，后者可以在多个通道之间共享参数。本文借鉴独立建模的思路，并通过同尺度的七通道输入对照检查负荷信息是否改善油温预测。

2.2 线性预测与水平恢复

LTSF-Linear 系列包括直接线性映射、末值参考的 NLinear 和趋势分解的 DLinear[4]。其 ETT 单变量实验说明，在该任务中应当将线性预测器纳入主要候选。本文采用带二次正则化的多输出 Ridge，并以最近 24 h 均值替换单个末值作为局部参考，使模型围绕短时平均温度学习未来偏移。

RevIN 使用窗口均值与标准差变换输入，在预测后恢复原尺度 [9]。本文的局部水平锚定只减去 24 h 均值，不进行逐窗口方差缩放；固定尺度则在训练段估计。这使参考水平的恢复与残差幅度的学习相互分离。窗口均值与标准差归一化作为补充对照，检验尺度处理在当前油温任务中的作用。

2.3 预测结构与序列表示

MLP 将整个历史窗口映射为未来向量，GRU 与 LSTM 通过门控状态编码时间顺序；它们分别提供非线性映射和循环状态对照。DLinear、PatchTST 与 SegRNN 分别代表分解线性映射、片段注意力和片段循环预测 [4, 5, 8]。本文依据这些已有结构构建对照模型，关注它们在同一油温目标上的误差及其与局部水平处理的关系。

3 油温数据与任务设置

3.1 数据与质量问题

原始文件包含 17,420 行，时间范围为 2016-07-01 00:00 至 2018-06-26 19:00，时间间隔为 1 h。字段包含六个负荷变量和油温 OT；时间戳无重复，数值无 NaN。图 1 展示完整序列与实验使用的时间段，低温测试段与训练段的水平差异直接可见。

质量检查发现，所有含 31 日的月份都出现整日七列冻结，共 14 天、336 行。标准测试段中含 3 个冻结日，即 72 行，占该段 2.5%。此外，训练段在 2016 年 12 月存在负荷零值块，验证段的两个低负荷通道存在 141 h 恒值块。这些常量与零值按采集伪影记录；当前实验保留原始数值，因此结果反映含伪影数据上的预测误差。

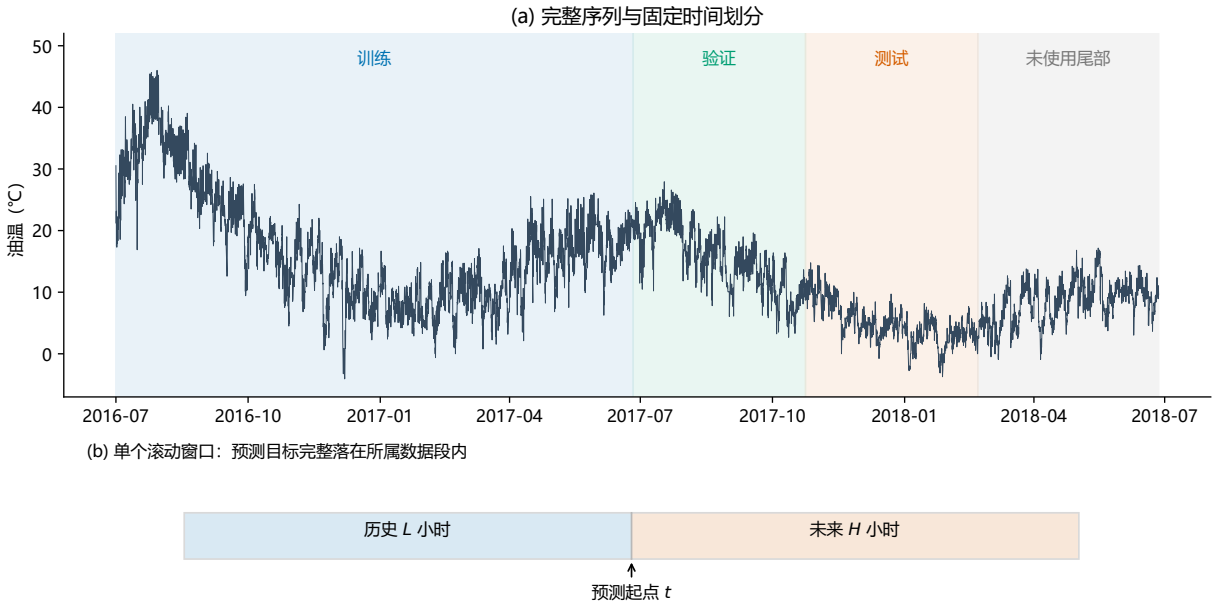


图 1: 油温序列、时间划分与滚动窗口。上图阴影表示训练、验证、测试及未使用尾部；下图表示一个预测起点对应的历史与目标。验证和测试输入可跨越前一段边界，预测目标保持在所属数据段内。

3.2 探索性分析与处理

训练段 OT 的 1 h 和 24 h 滞后自相关分别为 0.994 和 0.940，说明近期油温具有较强持续性。训练段按月份分组可解释 81.1% 的方差，在此基础上加入小时分组再解释 5.7%。这些数值描述样本内的季节与日内变化，为采用近期水平和历史窗口提供依据。

训练、验证和测试段 OT 均值分别为 17.13、15.58 和 4.85 ℃。不同时间段的水平差异提示模型需要适应当前温度。原始时间序列保留用于标准划分评价；窗口中心化和训练段标准化用于模型输入，数据质量问题及其可能影响在讨论中说明。

3.3 任务与滚动窗口

设小时油温为 y_t，历史长度为 L，预测长度为 H，单变量输入与目标定义为

$$\mathbf{x}_t = (y_{t-L+1}, \ldots, y_t)^\top \in \mathbb{R}^L, \qquad \mathbf{y}_t = (y_{t+1}, \ldots, y_{t+H})^\top \in \mathbb{R}^H. \tag{1}$$

单变量设置记为 S 模式。默认 $L = H = 96$，即根据过去 4 天预测未来 4 天。模型一次生成全部 H 个输出；预测期间使用同一输入窗口，逐步误差可按未来小时位置分别统计。

固定划分以每月 30 天换算，行索引与日期见表 1。末尾 3,020 行不参与；测试时间覆盖晚秋至冬季。每次预测起点前移 1 h，仅保留目标完整落在对应段内的窗口，因此训练窗口数为 $8640 - L - H + 1$，验证与测试各为 $2880 - H + 1$。

额外负载实验采用多变量输入、单变量输出的 MS 模式。输入为 $L \times 7$ 矩阵，预测目标仍为未来油温。长历史实验取 $L = 336$、$H = 96$；验证与测试目标及预测起点保持相同，训练窗口数降至 8,209。该设置为输入信息与历史长度比较提供共同的目标集合。

表 1: 固定划分与默认 96 h 历史、96 h 预测的样本数。日期均含末日 23:00。训练段前 96 h 仅用于构造首个输入。

数据段	行数	窗口数	行索引	日期范围
训练	8,640	8,449	$[0, 8640)$	2016-07-01 至 2017-06-25
验证	2,880	2,785	$[8640, 11520)$	2017-06-26 至 2017-10-23
测试	2,880	2,785	$[11520, 14400)$	2017-10-24 至 2018-02-20

3.4 标准化与模型选择

所有固定尺度统计量均在训练窗口上拟合。按滞后标准化为输入的每个小时位置分别估计均值与标准差；按变量标准化则将所有训练窗口的时间位置合并，每个变量使用一个均值与标准差。表 2 给出各模型采用的方式。

表 2: 各模型的标准化方式。目标标准化发生在锚定之后；预测时先反标准化，再恢复输入窗口的参考水平。

模型	输入尺度	目标尺度
96 h Ridge	按滞后	保留油温残差单位
MLP、PatchTST、片段混合 MLP	按滞后	按预测步
GRU、LSTM	单变量合并时间位置	按预测步
DLinear、SegRNN	单变量合并时间位置	合并全部预测步
192/336/720 h Ridge	按滞后	按预测步
MS Ridge 及其 S 对照	按变量	合并全部预测步

Ridge 正则化强度取 $\{0.1, 1, 10, 100, 1000\}$，按验证集平均绝对误差（Mean Absolute Error, MAE）选择。神经模型使用均方误差（Mean Squared Error, MSE）损失和 Adam 优化器。学习率为 10^{-3}，权重衰减为 10^{-4}，批量大小为 256，梯度范数裁剪阈值为 1。最多训练 300 轮，验证 MAE 连续 20 轮未改善时停止，并恢复验证 MAE 最低的参数。随机种子取 0、1、2，训练设备为 RTX 5090 Laptop GPU，软件为 PyTorch 2.14.1 与 CUDA 13.0。

表 2 中的输入与目标尺度因模型而异。水平处理的对照在同一模型内部进行；负载输入实验另外设置同尺度 S 对照。跨家族结果用于比较这些具体训练方案的总体误差，结构作用的讨论结合对应消融进行。

3.5 指标与统计比较

设测试窗口数为 N，误差 $e_{i,h} = \hat{y}_{i,h} - y_{i,h}$，则

$$\mathrm{MSE} = \frac{1}{NH}\sum_{i,h} e_{i,h}^2, \quad \mathrm{MAE} = \frac{1}{NH}\sum_{i,h} |e_{i,h}|, \quad \mathrm{Bias} = \frac{1}{NH}\sum_{i,h} e_{i,h}. \tag{2}$$

MSE 单位为 $^\circ\mathrm{C}^2$，MAE 与平均偏差单位为 $^\circ\mathrm{C}$。所有主结果在恢复原始油温单位后计算；正偏差表示整体高估。相对基线的 MAE 改善率定义为 $1 - \mathrm{MAE}_{\mathrm{model}}/\mathrm{MAE}_{\mathrm{ref}}$，正值表示误差较低。

三种子指标均值是先计算每次训练的指标，再对三个数取平均；其标准差使用样本标准差。预测集成则先计算 $\hat{\mathbf{y}}^{\mathrm{ens}} = \frac{1}{3}\sum_{s=1}^{3}\hat{\mathbf{y}}^{(s)}$，再计算指标。误差中的绝对值与平方使两者通常不同，因此分别报告。

配对比较先在每个窗口上计算两个模型的 MAE 或 MSE 差，再沿预测起点序列抽取连续 96 个窗口组成的块。每次有放回抽块，拼接并截取至原样本数，重复 2,000 次，取均值差的 2.5% 和 97.5% 分位数作为区间。本文沿用已保存的块长；当 $H > 96$ 时，目标重叠可能延续到更远起点，区间解释需结合这一依赖长度。

步内去偏误差以 $\bar{e}_h = N^{-1}\sum_i e_{i,h}$ 为每个预测步的平均误差，计算 $e_{i,h} - \bar{e}_h$ 的 MSE 或 MAE。由于 $\bar{e}_h$ 使用测试真值，该指标仅用于诊断水平误差，在预测阶段不参与校正。主结果仍使用未经测试标签校正的预测。

4 统计基线

以训练段均值、最后观测值、最近 24 h 均值、最近 96 h 均值和最近 24 h 周期复制构成五个统计基线。前四者分别保持全局水平、最新水平或近期平均水平；周期复制按时间顺序重复最近一天的油温变化。

表 3: 五个统计基线在测试集上的平均绝对误差（℃）。每个预测长度使用其全部有效测试窗口。

预测规则	96 h	192 h	336 h	720 h
训练段均值	12.324	12.408	12.528	12.758
最后观测值	1.865	2.163	2.434	2.601
最近 24 h 均值	1.820	2.082	2.342	2.488
最近 96 h 均值	1.821	2.063	2.275	2.395
24 h 周期复制	1.932	2.173	2.417	2.566

表 3 显示，训练段均值在测试段产生较大误差；局部均值与最后值更接近测试段温度水平。96 h 预测中，24 h 均值的 MAE 为 1.820 ℃，略低于 96 h 均值；192 h 及更长预测中，96 h 均值较低。24 h 均值因此作为后续锚定模型的参考基线。

5 从线性回归到局部水平锚定

统计基线表明，局部水平本身已经解释了相当一部分误差：最近 24 h 均值（B2a）在 96 h 任务上的 MAE 为 1.820 ℃。一个自然的改进是把 96 h 历史直接映射到 96 h 未来。我们先拟合普通多输出 Ridge，再根据其误差结构决定是否以及如何引入水平处理。

5.1 普通 Ridge 的水平偏差

普通 Ridge 以 96 h 绝对油温为输入，输出 96 h 绝对油温；输入在训练段按滞后标准化，输出保留摄氏度，正则化强度由验证集 MAE 选择。验证集上 $\alpha = 10$ 最优，测试集 MSE 为 5.107、

MAE 为 1.670 ℃、平均偏差为 +0.780 ℃。单看 MAE，它比 B2a 低 8.2%，但偏差远高于 B2a 的 +0.144 ℃。

普通 Ridge 的偏差随预测步单调增加：第 1–24 h 为 +0.317 ℃，第 73–96 h 达 +1.105 ℃（表 5）。训练段 OT 均值约为 17.13 ℃，测试段约为 14.85 ℃。普通 Ridge 的系数和接近 1，截距随预测步从 0.04 增至 1.21；当输入来自较低水平的测试段时，模型仍把预测拉向训练段均值，因而在冬季高估。这说明误差不是随机波动，而是系统性的水平偏移。

若按测试集每个预测步的真实平均误差扣除偏差（仅用于诊断），普通 Ridge 的 MSE 从 5.107 降至 4.400，MAE 从 1.670 降至 1.604；加入局部水平锚定后的 Ridge（下称 Anchored Ridge）去偏前后几乎不变（4.613 至 4.598，1.632 至 1.640）。这说明普通 Ridge 的形状并不差，主要瓶颈是水平漂移；锚定的价值在于把水平从绝对温度中分离出来，而不是提升形状建模能力。

验证集与测试集的差异也支持这一判断：验证集上普通 Ridge 的 MAE 为 2.229 ℃，略优于 Anchored Ridge 的 2.256 ℃；测试集上分别为 1.670 和 1.632 ℃。验证段处于夏秋、水平漂移较小，测试段进入冬季、漂移较大，锚定的收益主要在后者显现。

表 4: 96 h 输入、96 h 输出的水平诊断。B2a 为最近 24 h 均值基线。去偏 MSE/MAE 按测试集每个预测步的真实平均误差扣除，仅用于区分水平误差与形状误差，不参与预测。

模型	MSE	MAE	平均偏差	去偏 MSE	去偏 MAE
普通 Ridge	5.107	1.670	+0.780	4.400	1.604
Anchored Ridge	4.613	1.632	+0.105	4.598	1.640
B2a（24 h 均值）	5.454	1.820	+0.144	5.428	1.829

表 5: 测试集分段的平均偏差（℃）。各段对应预测步 1–24、25–48、49–72 和 73–96。

模型	1–24	25–48	49–72	73–96
普通 Ridge	+0.317	+0.737	+0.963	+1.105
Anchored Ridge	+0.030	+0.078	+0.131	+0.182
B2a（24 h 均值）	+0.050	+0.107	+0.172	+0.248

5.2 参考水平与残差

上述诊断把改进方向限定为水平处理：与其让线性映射同时学习绝对温度和未来变化，不如先把当前水平显式分离出来。局部水平取最近 24 h 均值

$$\ell_t = \ell_t^{(24)} = \frac{1}{24}\sum_{i=0}^{23} y_{t-i}, \tag{3}$$

并构造

$$\mathbf{x}_t^c = \mathbf{x}_t - \ell_t \mathbf{1}_L, \qquad \mathbf{y}_t^c = \mathbf{y}_t - \ell_t \mathbf{1}_H. \tag{4}$$

训练时参考水平由输入计算，目标与输入减去同一数值；预测时模型生成未来相对该水平的偏移量，再加回 ℓ_t。图 2 将参考水平作为独立支路接入输出端，说明中心化输入和恢复水平使用同一历史统计量。

最后观测值对噪声敏感，96 h 均值更平滑但在快速变化时滞后；在 96 h 任务上，24 h 均值、最后值和 96 h 均值的 MAE 分别为 1.820、1.865 和 1.821 ℃。24 h 均值略优，因此作为主实验的参考；长预测中 96 h 均值略优，本文保留 24 h 以保持参考定义一致，并在后文长预测实验中与统计基线比较。该锚定的零模型是 B2a，Ridge 只学习相对偏移。

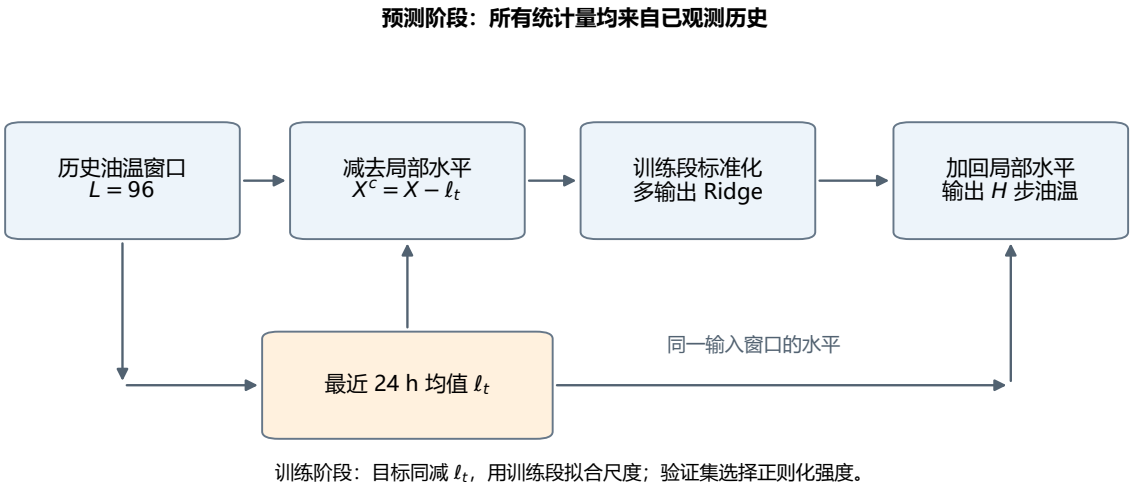


图 2: Anchored Ridge 的预测流程。历史输入分成残差建模与水平恢复两条支路。图中预测头输出油温残差；96 h 主实验的目标保留原单位，长预测实验则在头部输出后先完成目标反标准化。

5.3 多输出 Ridge 与正则化

Ridge 在最小二乘损失中加入系数的二次惩罚。多输出 Ridge 用同一历史窗口分别拟合各个未来小时的温度。对 n 个训练窗口，按滞后标准化后的输入矩阵记为 $Z \in \mathbb{R}^{n\times L}$，目标残差记为 $R \in \mathbb{R}^{n\times H}$。参数 $W \in \mathbb{R}^{L\times H}$ 与 $b \in \mathbb{R}^{H}$ 通过

$$\min_{W,b} \ \|R - ZW - \mathbf{1}_n b^\top\|_F^2 + \alpha\|W\|_F^2 \tag{5}$$

求解。截距不受惩罚；每个预测步有一组历史权重。预测为 $\hat{\mathbf{y}}_t = W^\top \mathbf{z}_t + b + \ell_t \mathbf{1}_H$，因此 96 h 历史到 96 h 输出含 $96 \times 96 + 96 = 9{,}312$ 个回归系数与截距。

采用直接多步而非递归，是因为每个未来小时可以独立拟合一组权重，避免一步预测误差沿预测区间累积；所有模型使用同一输入窗口，也便于与统计基线逐窗口比较。锚定后 α 网格扩展到 $\{0.1, 1, 10, 100, 1000\}$，验证 MAE 选中 $\alpha = 100$；0.1 到 100 的测试 MAE 差异小于 0.001 ℃，说明相对偏移中的可学信号较弱，强正则化把模型压向 B2a，同时保留稳定的偏差修正。

若输入整体加上常数 c，局部均值也增加 c，中心化输入保持相同；固定标准化后的残差预测相同，最终输出增加 c。因此，该预测器对输入整体平移具有等变性。它显式保留当前水平，使线性映射主要拟合未来偏移量。当残差预测在原单位下为零时，模型退化为 24 h 均值预测；实际拟合的权重由训练损失与正则化决定。

5.4 线性模型比较与选择

普通 Ridge、Anchored Ridge 与 DLinear 的比较见表 7：普通 Ridge 的测试 MAE 为 1.670 ℃，Anchored Ridge 为 1.632 ℃，锚定 DLinear 的三种子均值为 1.635 ℃。Anchored Ridge 的平均偏差从普通 Ridge 的 +0.780 ℃ 降至 +0.105 ℃。

Anchored Ridge 相对普通 Ridge 的 MAE 仅降低 2.2%，MSE 降低 9.7%；配对 bootstrap 的 MAE 差为 −0.037 ℃，95% 区间为 $[-0.149, +0.091]$ ℃，跨零；相对 B2a 的 MAE 差为 −0.187 ℃，区间为 $[-0.294, -0.072]$ ℃，不跨零。因此，锚定的稳健收益主要是相对局部均值基线，而不是相对普通 Ridge 的逐窗口优势；后者的改善集中在水平漂移较大的窗口。

DLinear 通过趋势分解实现类似水平处理：绝对值版本的 MAE 为 1.843 ℃，锚定版本为 1.635 ℃，与 Anchored Ridge 相差约 0.003 ℃。这说明水平信息可以由不同结构捕捉，而不是某一种网络独有。本文选择 Anchored Ridge 作为后续单模型参照，原因是参数少、求解确定且无需随机种子；这一选择不意味着线性模型在形状上优于所有神经模型，后文将直接在锚定残差上检验非线性模型。

6 非线性模型能否改善预测

第 5 节表明，水平锚定已经把绝对温度中的系统性偏移分离出去，剩余的是相对当前水平的未来变化。一个自然的问题是：在这部分残差上，非线性模型能否比线性映射学得更好？如果误差主要来自水平而不是形状，增加网络容量就不应带来稳定收益。为检验这一点，本节在同一划分、同一 96 h 输入和同一 24 h 锚定下比较 MLP、GRU、LSTM、PatchTST 与 SegRNN，并进一步检查预测集成、预测长度、负载输入、历史长度和片段交互。结果是：水平处理显著改善了绝对值神经模型，但没有哪种非线性结构在单模型指标上稳定超过 Anchored Ridge；复杂度带来的变化主要落在种子波动和集成方式之内。

6.1 对照模型与输入

为确定油温预测器，比较线性、多层感知机、循环网络与片段模型。各模型均直接生成完整预测向量，绝对值版本预测标准化油温，锚定版本预测相对局部水平的偏移量。表 6 概括主要结构；附录 A 展开门控状态、分解算子、片段编码和并行解码过程。

表 6: 对照模型与油温输入的映射方式。默认历史和预测长度均为 96 h，SegRNN 为 336 h 历史。PatchTST 按嵌入宽度区分。

模型	从历史到未来的映射	参数量
MLP	两层 128 单元隐藏层，ReLU，直接输出	41,312
GRU	单层 64 维门控状态，末状态接线性头	19,104
LSTM	单层 64 维记忆与隐藏状态，接线性头	23,392
PatchTST 64 维	16 h 片段、8 h 步长、2 层编码	136,416
PatchTST 16 维	同一片段划分，3 层编码	24,112
SegRNN	48 h 分段，GRU 编码与并行预测	31,344

输入对照分别检验六个负荷变量和更长历史：前者将油温输入扩为 96 h 七通道记录，后者将单变量历史延长至 336 h。片段交互对照保留 16 维 PatchTST 的嵌入与预测头，以参数量接近的片段混合 MLP 替换自注意力。这些比较为最终输入和模型选择提供依据。

6.2 水平处理与预测误差

主实验固定输入与输出长度，先比较局部水平处理，再比较模型结构。默认 96 h 输入、96 h 输出下，最后值、24 h 均值、96 h 均值的测试 MAE 分别为 1.865、1.820、1.821 ℃。24 h 均值在这组基线中略低；后续长预测另外保留 96 h 均值作对照。表 7 给出不同预测器在未来 96 h 油温上的误差。

表 7: S 模式 96 h 输入、96 h 输出结果。神经模型报告三种子指标均值 ± 样本标准差；偏差为三种子均值。MSE 单位为 $℃^2$，MAE 和偏差单位为 ℃。16 维 PatchTST 与片段混合 MLP 只运行了锚定版本。

模型	MSE	MAE	平均偏差
Ridge（绝对值）	5.107	1.670	+0.780
Anchored Ridge	4.613	1.632	+0.105
MLP（绝对值）	12.198 ± 1.314	2.853 ± 0.186	+2.678
MLP（锚定）	4.680 ± 0.040	1.663 ± 0.006	−0.034
GRU（绝对值）	17.878 ± 1.040	3.532 ± 0.120	+3.331
GRU（锚定）	4.776 ± 0.208	1.671 ± 0.024	−0.030
LSTM（绝对值）	18.243 ± 0.031	3.565 ± 0.003	+3.339
LSTM（锚定）	5.077 ± 0.252	1.759 ± 0.044	−0.202
DLinear（绝对值）	6.224 ± 0.245	1.843 ± 0.036	+1.264
DLinear（锚定）	4.616 ± 0.004	1.635 ± 0.003	+0.093
PatchTST 64 维（绝对值）	11.250 ± 1.699	2.712 ± 0.262	+2.330
PatchTST 64 维（锚定）	4.777 ± 0.123	1.655 ± 0.035	+0.084
PatchTST 16 维（锚定）	4.842 ± 0.286	1.644 ± 0.034	+0.301
片段混合 MLP（锚定）	4.709 ± 0.028	1.684 ± 0.005	−0.010

绝对值 MLP、GRU、LSTM 的 MAE 为 2.853、3.532、3.565 ℃，均高于局部均值。锚定后，它们分别降至 1.663、1.671、1.759 ℃；对应平均偏差从 2.678、3.331、3.339 ℃ 降至接近零或较小负值。图 3(b) 对相同结构进行配对展示，支持在本数据划分下优先处理水平差异。

Anchored Ridge 的 MSE 为 4.613、MAE 为 1.632 ℃，较绝对值 Ridge 分别降低约 9.7% 和 2.2%。锚定 DLinear 的 MAE 为 1.635 ℃，相差约 0.003 ℃。两种锚定 PatchTST 的三种子 MAE 均值为 1.644 与 1.655 ℃。这些差异小于多种神经模型自身的种子波动，因此采用 Anchored Ridge 作为单模型油温预测方案。

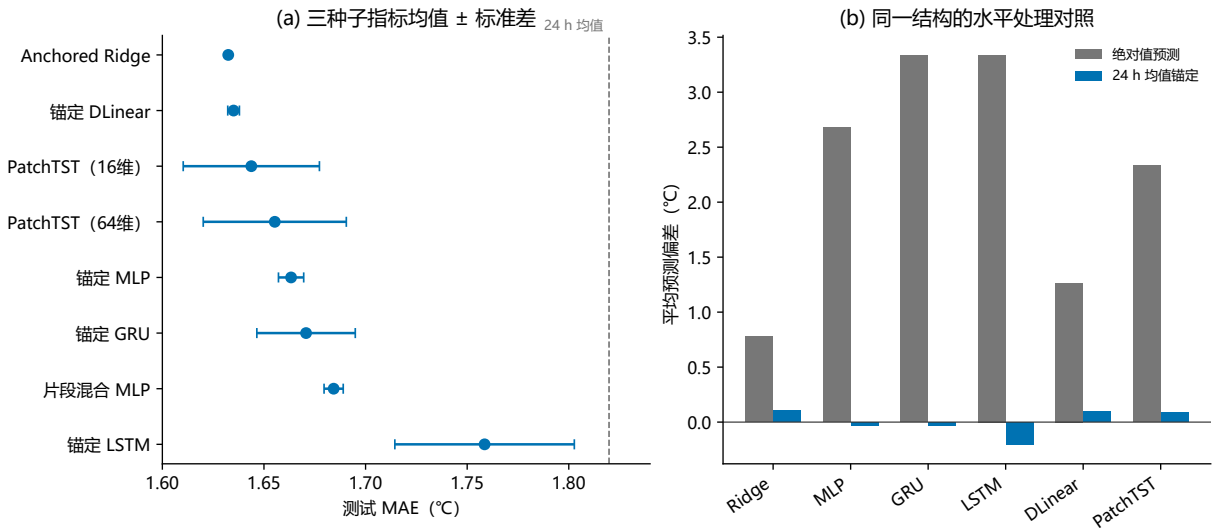


图 3: 96 h 预测的误差与偏差。(a) 点表示三种子 MAE 均值，误差线表示种子标准差，Ridge 为确定性结果；虚线为 24 h 均值基线。(b) 水平处理对照中的 PatchTST 采用 64 维、2 层配置。两图均使用 96 h 历史。

6.3 预测集成与归一化

输出平均可以抵消部分独立训练的预测波动。表 8 将种子指标均值与预测集成并列。16 维 PatchTST 集成 MAE 为 1.600 ℃，低于 Anchored Ridge 的点估计；锚定 GRU 集成的 MSE 为 4.525，也低于该 Ridge。模型比较因此同时考虑所用模型数量与评价指标。

表 8: 三种子指标均值与预测集成。所有模型采用 96 h 历史和 24 h 均值锚定。指标均值表示三次独立训练的平均；集成表示三个预测向量平均后的结果。

	种子指标均值		预测集成	
模型	MSE	MAE	MSE	MAE
MLP	4.680	1.663	4.641	1.655
GRU	4.776	1.671	4.525	1.624
LSTM	5.077	1.759	4.864	1.722
DLinear	4.616	1.635	4.607	1.633
PatchTST 64 维	4.777	1.655	4.617	1.623
PatchTST 16 维	4.842	1.644	4.632	1.600
片段混合 MLP	4.709	1.684	4.585	1.660

64 维 PatchTST 还运行了窗口均值与标准差归一化：对每个窗口计算 μ_t 和 $s_t = \mathrm{std}(\mathbf{x}_t) + 10^{-8}$，输入与目标均按这两个统计量变换，输出再乘 s_t 并加 μ_t。该版本三种子 MAE 为 1.669 ℃，24 h 均值锚定为 1.655 ℃。该方法按各窗口统计量恢复油温，结果支持把均值处理与尺度处理分别检验。

6.4 延长预测长度

长预测实验保持历史长度相同，分别拟合不同长度的未来残差。保持 $L = 96$，每个 H 独立拟合 Ridge 并以验证 MAE 选择正则化强度。表 9 给出各自全部有效测试窗口，四个预测长度均选中 $\alpha = 100$。192 h 额外运行的锚定 PatchTST 三种子 MAE 为 1.993 ℃，集成为 1.935 ℃，该长度的 Ridge 为 1.914 ℃。

表 9: 96 h 历史下的跨预测长度结果。每行使用对应长度的全部有效测试窗口。MAE 改善率以同一行的 96 h 均值为参考。336 h 与 720 h 的模型比较仅包含 Ridge 和统计基线。

H	窗口数	Ridge MSE	Ridge MAE	均值 MAE	MAE 改善率
96	2785	4.613	1.632	1.821	10.37%
192	2689	6.178	1.914	2.063	7.23%
336	2545	7.310	2.129	2.275	6.43%
720	2161	7.092	2.116	2.395	11.65%

预测长度增大时，有效起点数从 2,785 降至 2,161，因此表中跨行差异同时包含目标长度和起点集合变化。图 4(a) 在相同的 2,161 个起点上比较各预测长度：Ridge MAE 随 H 从 96 增至 720，依次为 1.594、1.892、2.072、2.116 ℃。在共同起点下，336 h 至 720 h 的平均误差仍增加，但增幅较前两个区间小。

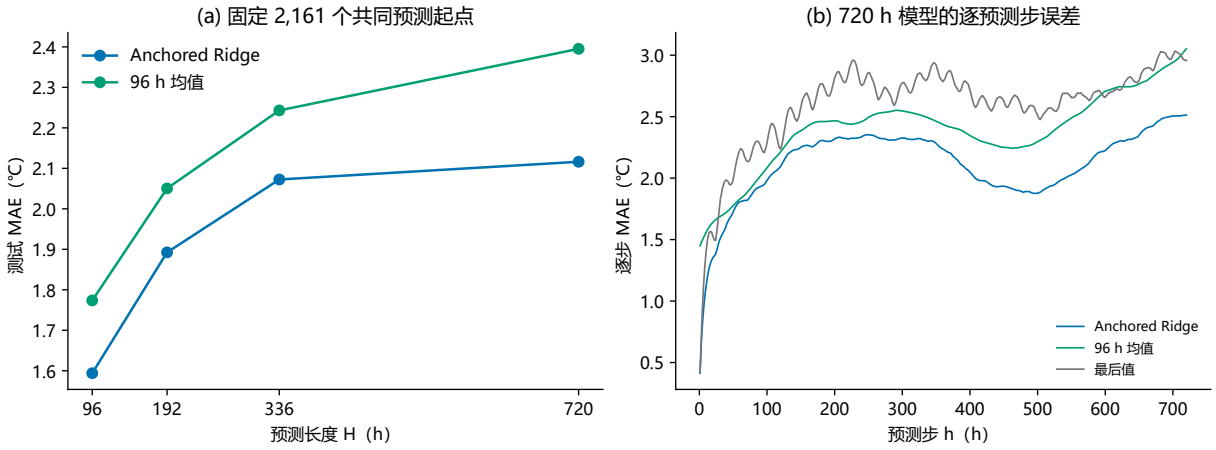


图 4: 长预测的两个观察角度。(a) 每个预测长度独立拟合模型，在相同 2,161 个预测起点上计算整个目标区间的平均 MAE。(b) 固定 720 h 模型，分别计算第 h 小时误差。前者考察整个区间，后者展示未来位置变化，两者分别解释。

720 h 模型的平均偏差仍为 +0.604 ℃，说明当前水平恢复后，远期温度变化仍有系统性误差。逐步误差曲线也保留较大的远期波动。因此，现有实验支持 Anchored Ridge 在长预测中优于所比较的局部水平基线，并提示继续研究随季节变化的未来水平。

6.5 负载输入与历史长度

输入消融分别增加负载通道与历史小时数。七通道 Ridge 只对 OT 减去局部油温均值，其他负载通道保留原值，再按变量标准化并展平为 672 维输入。对应的单变量对照同样采用按变量标准化，MAE 为 1.633 ℃；七通道版本为 1.795 ℃。配对 MAE 差为 +0.163 ℃，95% 区间为 $[+0.113, +0.226]$ ℃，因此当前线性输入拼接方案保留单变量设置。

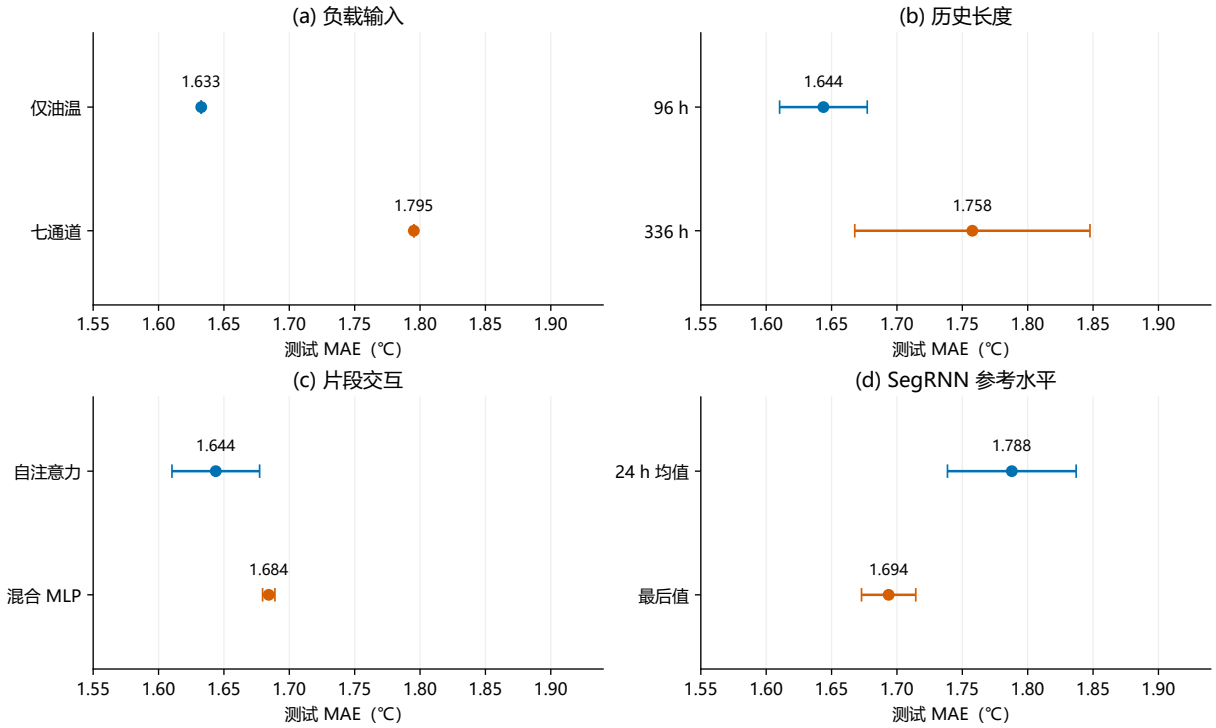


图 5: 四组消融的测试 MAE。神经模型点为三种子指标均值，误差线为种子标准差；确定性 Ridge 无种子误差线。历史长度图采用 16 维 PatchTST，SegRNN 图采用 336 h 历史。种子误差线与正文的窗口块重采样区间描述不同的波动来源。

历史长度比较如图 5(b)。Ridge 从 96 h 延长至 336 h 后，MAE 由 1.632 降至 1.625 ℃，配对差区间为 $[-0.152, +0.112]$ ℃，逐窗口胜率约 49.6%。16 维 PatchTST 的三种子 MAE 从 1.644 升至 1.758 ℃；预测集成从 1.600 升至 1.692 ℃，配对集成 MAE 差区间为 $[-0.070, +0.230]$ ℃。因此，已测长历史方案未提供明确的误差降低证据。

延长历史也将 PatchTST 片段数从 11 增为 41，参数量从 24,112 增至 70,672。三个长历史种子均在第 1 轮取得最低验证 MAE，随后在耐心轮数内停止训练。该结果同时涉及更长输入、更宽展平预测头和较少训练窗口，因此后续长历史比较需控制预测头容量。

6.6 注意力与片段循环

片段结构实验分别替换交互机制与参考水平。自注意力替换为片段混合 MLP 后，三种子 MAE 均值从 1.644 增至 1.684 ℃，MSE 从 4.842 降至 4.709。两个预测集成的配对 MAE 差为 +0.059 ℃，95% 区间为 $[-0.041, +0.142]$ ℃；MSE 差为 −0.047，区间同样跨零。因此，该 11 片段小模型中，两种交互方式在现有测试窗口上的差异仍有较大不确定性。

片段混合 MLP 的种子 MAE 标准差为 0.005 ℃，注意力模型为 0.034 ℃；注意力模型的预测集成 MAE 较低。前者显示单次训练波动较小，后者显示输出平均对该注意力模型有效。两种结果分别保留，用于选择单模型方案或三模型集成方案。

SegRNN 采用 336 h 历史时，24 h 均值锚定版本的三种子 MAE 为 1.788 ± 0.049 ℃，末值参考版本为 1.694 ± 0.021 ℃。对应预测集成为 1.779 和 1.687 ℃，配对差“均值参考减末值参考”的区间为 $[+0.060, +0.120]$ ℃。因此，该结构采用末值参考更合适。

6.7 小结：非线性没有形成稳定增益

把 96 h 主结果、集成、长预测和输入消融放在一起，可以得到一致结论：非线性模型的主要收益来自水平锚定，而不是结构本身。绝对值的 MLP、GRU、LSTM 和 PatchTST 误差很高，锚定后立即降到与线性模型相近的范围；在锚定残差上继续增加深度、门控或注意力，没有把单模型 MAE 压到 1.632 ℃ 以下。16 维 PatchTST 的三模型集成达到 1.600 ℃，GRU 集成在 MSE 上达到 4.525，说明集成可以降低方差，但这需要三个网络和三次训练，不能解释为单一非线性结构的优势。负载通道、336 h 历史和自注意力替换也未提供稳定增益。因此，本文不把“更复杂的结构”作为最终方案，而把 Anchored Ridge 作为单模型基线；非线性模型的价值在于验证这一基线，而不是取代它。

7 讨论：模型复杂度与预测误差

7.1 模型选择与已有研究

综合油温误差、输入需求和模型规模，最终选用 Anchored Ridge：输入最近 96 h OT，以最近 24 h 均值为参考，通过多输出 Ridge 预测未来油温。该模型在默认单变量任务中的 MAE 低于所比较神经模型的三种子指标均值，与锚定 DLinear 接近；其回归系数与截距共 9,312 个，约为 DLinear 参数量的一半。求解过程确定，预测只需固定的线性映射，因此适合作为本任务的单模型方案。

历史延长至 336 h 的 Ridge 取得更低的测试 MAE 点估计 1.625 ℃，但与 96 h 版本的配对差区间跨零，输入长度增加到 3.5 倍。七通道输入的误差更高，已测神经结构也未在单模型指标均值上形成一致优势。最终保留 96 h 的 OT 输入，以相同历史长度支持后续不同预测区间。

表 10 汇总最终预测器的组成。24 h 均值决定当前温度参考，多输出 Ridge 学习未来偏移；训练尺度固定后，每次预测只需更新输入窗口与局部均值。该方案的选择同时依据温度误差、输入范围和确定性求解的特点。

7.2 最终预测器的计算

在预测起点 t，读取 $\mathbf{x}_t$ 并计算 ℓ_t，按式 (4) 得到历史残差。使用训练段拟合的均值与标准差变换残差，再通过式 (5) 对应的预测映射生成未来偏移。输出端加回同一 ℓ_t，得到 $t+1$ 至 $t+96$ 的油温预测。新观测到达后，窗口向前移动 1 h，重新计算局部参考并生成下一次预测。

表 10: 最终选用的 Anchored Ridge 油温预测器。所有输入均在预测起点前已观测，目标为未来 OT。

组成	取值或处理
输入变量	小时级 OT，单变量 S 模式
历史长度	最近 96 h
局部参考	最近 24 h 油温均值
输入变换	减去局部参考，按训练段各滞后位置标准化
预测映射	多输出 Ridge，$\alpha = 100$
输出处理	加回输入窗口的局部参考
主要输出	未来 96 h 油温向量，单位为 ℃
测试误差	MSE 4.613 $℃^2$，MAE 1.632 ℃

整个计算只依赖预测起点前的 OT。训练目标同样减去输入窗口的参考水平，因此模型学习的是未来温度相对当前平均水平的变化。需要 192、336 或 720 h 预测时，保持这一输入与恢复过程，对相应长度独立拟合输出映射；表 9 给出了这些预测器的误差。

图 6 展示两个固定日历时刻的预测。灰色曲线为输入历史，黑色曲线为随后观测到的真实油温，蓝色曲线为 Anchored Ridge 的输出。两个时刻按日期预先确定，用于展示模型如何从当前水平延伸出未来变化；总体效果由全部测试窗口的指标评价。

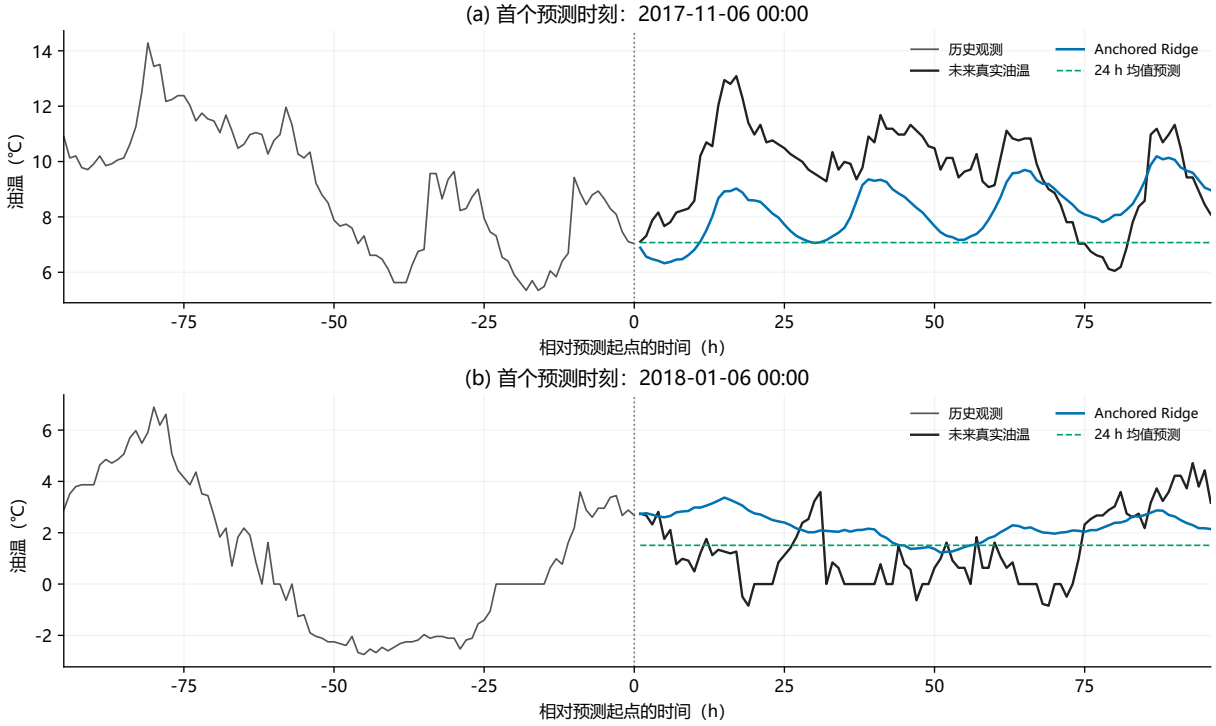


图 6: Anchored Ridge 的 96 h 油温预测示例。竖线为预测起点，右侧真实油温用于事后评价；绿色虚线为 24 h 均值预测。两个首个预测时刻分别固定为 2017-11-06 与 2018-01-06 的 00:00，不按误差筛选。

与将局部均值平铺至未来的预测相比，线性映射能够给出随预测步变化的温度修正。在整个测试集上，第 1–24 h 的 MAE 为 1.129 ℃，第 73–96 h 为 1.929 ℃，表明未来变化越远，误差越大。两个示例中的预测曲线也会偏离实际短时波动，因此该方案主要提供未来油温的点预测序列。

7.3 线性模型表现的可能原因

Huang 等使用 Ridge 和局部归一化，在多个基准上比较线性与非线性方法，强调输入处理和模型配置的作用 [10]。其多变量基准按通道独立建模，本研究聚焦 OT 单变量输入；两者采用的归一化范围和训练设置不同。本文的线性模型在已测单模型设置中取得较低误差，这与该预印本中线性预测器具有竞争力的观察方向一致。训练段油温的高自相关和测试段水平变化，为线性模型结合局部参考提供了可能的解释；这些统计关系支持机制分析，也需要更多划分检验。

最终方案与 NLinear 共享参考水平恢复的思想：先在相对温度上学习，再恢复绝对温度 [4]。本文使用 24 h 均值作为参考，并通过二次正则化拟合多输出线性映射。96 h 输入整体平移后，预测随之平移，这使当前水平可以直接进入未来温度估计；测试段的偏差变化与这一机制一致。

DLinear 通过移动平均和双分支线性映射处理趋势 [4]，本文的 Anchored Ridge 则将局部水平单独恢复。二者在 96 h 预测中误差接近，说明这一具体任务可以由较简单的温度表示与映射完成。RevIN 对窗口均值与尺度的处理提供了另一种分布适应方式 [9]；当前实验中，保留残差幅度的局部均值锚定已取得较低误差。

单模型选择与预测集成需结合使用条件分别考虑。16 维 PatchTST 的三种子预测集成 MAE 为 1.600 ℃，低于最终单模型的点估计；GRU 集成也在 MSE 上取得较低误差。对于允许多个网络共同预测的应用，这些集成仍是可选方案。本文最终给出的 Ridge 则提供一套输入明确、参数固定且易于计算的单模型油温预测方法。

7.4 适用条件与改进方向

当前评价基于 ETTh1 的固定时间划分，测试段集中在晚秋至冬季。数据包含冻结日与负荷采集伪影，尚需在全年滚动评价及冻结日敏感性分析中检查误差变化。尤其在长预测区间，当前局部水平与数周后的真实水平可能出现差异，720 h 预测仍有 +0.604 ℃ 的平均偏差。

模型比较采用有限配置与三个随机种子，长历史实验还改变了预测头规模，336 h 和 720 h 预测主要与统计基线比较。后续工作可在容量匹配条件下比较长历史模型，并引入环境温度等可获得变量，检验其对未来 OT 的增量信息。温度预警还需要预测区间及越限概率，点预测误差为这些扩展提供基础。

8 结论

最终预测模型为 Anchored Ridge：以最近 96 h 油温为输入，减去最近 24 h 的均值，采用验证集选出的 $\alpha = 100$ 拟合多输出 Ridge，并在输出端恢复局部温度水平。该模型在 96 h 测试窗口上的 MSE 为 4.613 $℃^2$、MAE 为 1.632 ℃。

相对 24 h 均值基线，该预测器的 MAE 降低 10.3%。

在已测单模型设置中，局部水平处理的作用比继续增加结构复杂度更直接，线性方案与锚定 DLinear 的误差接近。保持相同输入长度，最终方案还可分别拟合 192、336、720 h 的预测映射。研究由此给出面向 OT 的具体预测器，并将更长历史、额外变量与多模型集成保留为有明确评价条件的扩展方向。

A 对照模型的结构细节

A.1 感知机与循环网络

MLP 对整个窗口进行非线性映射，循环网络则按时间顺序更新状态。多层感知机（Multilayer Perceptron, MLP）采用两层 128 单元隐藏层：

$$h_1 = \mathrm{ReLU}(A_1 z + a_1), \quad h_2 = \mathrm{ReLU}(A_2 h_1 + a_2), \quad \hat{r} = A_3 h_2 + a_3. \tag{6}$$

默认尺寸依次为 $96 \to 128 \to 128 \to 96$，共 41,312 个参数。模型将整个窗口作为向量输入，直接学习历史位置之间的非线性组合。

门控循环单元（Gated Recurrent Unit, GRU）与长短期记忆网络（Long Short-Term Memory, LSTM）按小时顺序接收标量输入，均为单层、隐藏宽度 64。GRU 利用重置门和更新门控制历史状态，例如

$$r_j = \sigma(A_r x_j + U_r h_{j-1} + b_r), \quad z_j = \sigma(A_z x_j + U_z h_{j-1} + b_z), \quad h_j = (1 - z_j) \odot \tilde{h}_j + z_j \odot h_{j-1}, \tag{7}$$

其中 σ 为 sigmoid 函数，$\odot$ 表示逐元素乘积。候选状态为

$$\tilde{h}_j = \tanh(A_n x_j + a_n + r_j \odot (U_n h_{j-1} + b_n)). \tag{8}$$

更新门控制候选状态与前一时刻状态的比例，因此 GRU 可在逐小时编码中保留较慢变化的信息。

LSTM 另外维护记忆单元 c_j。令输入门、遗忘门、输出门分别为 i_j, f_j, o_j，各门均对当前输入与上一隐藏状态的仿射变换使用 sigmoid。候选记忆 g_j 则使用双曲正切函数，状态更新为

$$c_j = f_j \odot c_{j-1} + i_j \odot g_j, \qquad h_j = o_j \odot \tanh(c_j). \tag{9}$$

两种循环网络均从零初始状态编码历史，取最后隐藏状态 $h_L \in \mathbb{R}^{64}$，接 $64 \to H$ 线性头。GRU 与 LSTM 分别含 19,104 和 23,392 个参数，作为两种门控状态设计的对照。

循环计算发生在历史编码阶段，输出端一次生成 H 个值。绝对值版本在全局标准化空间预测油温，锚定版本在式 (4) 的残差空间预测，再恢复水平。这样可在相同循环结构内部检查水平处理对误差的作用。

A.2 分解线性模型

DLinear 对平滑趋势与短时残差分别预测，再合并两个分支。先对标准化输入做宽度 25、步长 1 的移动平均，在两端各重复边界值 12 次以保持长度。令该线性平滑算子为 M，则趋势 $T = Mz$，剩余项 $S = z - T$，预测为

$$\hat{r} = A_T T + a_T + A_S S + a_S. \tag{10}$$

两个线性头均为 $96 \to 96$，总参数量为 18,624；两支输出逐步相加后恢复原单位和参考水平。

移动平均与两个预测头均为线性或仿射映射，因此式 (10) 可写成 $[A_T M + A_S(I - M)]z + a_T + a_S$。这说明该模型仍属于仿射预测器，其差异主要来自参数化、分支优化与正则化。该性质为它与 Ridge 接近的结果提供结构解释。

A.3 片段 Transformer

PatchTST 将相邻小时组织为连续片段，以片段作为注意力输入 [5]。将标准化序列按长度 $P = 16$、步长 $S = 8$ 切成重叠片段，片段数为

$$N_p = \left\lfloor \frac{L - P}{S} \right\rfloor + 1. \tag{11}$$

$L = 96$ 时得到 11 个片段，$L = 336$ 时得到 41 个片段。模型仅使用完整片段；每个片段经 $16 \to d$ 线性嵌入并加可学习位置向量。输入张量从 $B \times L$ 变为 $B \times N_p \times d$，其中 B 为批量大小。

每个编码块使用前置层归一化。令输入为 U，则

$$V = U + \mathrm{Dropout}(\mathrm{MHA}(\mathrm{LN}(U))), \tag{12}$$

$$U^{+} = V + \mathrm{Dropout}(\mathrm{FFN}(\mathrm{LN}(V))). \tag{13}$$

多头自注意力（Multi-Head Attention, MHA）使用 4 个头；单头以 $\mathrm{softmax}(QK^{\top}/\sqrt{d_k})V_h$ 聚合片段表示。前馈网络（Feed-Forward Network, FFN）为 $d \to d_{\mathrm{ff}} \to d$，使用 GELU 激活。编码后展平所有片段，接 dropout 和 $N_p d \to H$ 线性头，完成直接多步预测。

图 7(a) 给出片段编码到预测头的连接，表 11 区分实验使用的配置。64 维、2 层模型用于绝对值、24 h 锚定与窗口均值尺度归一化比较；16 维、3 层模型用于注意力消融和长历史比较。两组配置在本文始终按嵌入宽度标记，分别对应独立的模型与结果。

表 11: PatchTST 实际配置。各配置均为 4 头注意力，编码与预测头 dropout 均为 0.1。参数量包含嵌入、位置向量、编码块和输出头。

L	H	d	层数	d_{ff}	参数量	用途
96	96	64	2	128	136,416	水平处理比较
96	96	16	3	32	24,112	片段交互对照
336	96	16	3	32	70,672	历史长度比较

A.4 片段交互替换

片段交互对照比较内容相关的注意力权重与固定参数映射。保留 16 维 PatchTST 的嵌入、位置编码、三层深度、前馈网络和预测头，将自注意力替换为跨片段 MLP。对 $B \times 11 \times 16$ 的归一化表示，先转置为 $B \times 16 \times 11$，沿片段轴应用 $11 \to 48 \to 11$ 的 GELU 网络，再转置回原形状并残差相加。

该模型各特征共享片段混合映射，dropout 为 0.1，其余训练设置沿用注意力版本。替换后的总参数量为 24,193，比注意力版本多 81，约为 0.34%。因此，这组实验在近似相同容量下比较内容相关注意力与固定参数片段映射，结果用于判断该小配置的片段交互需求。

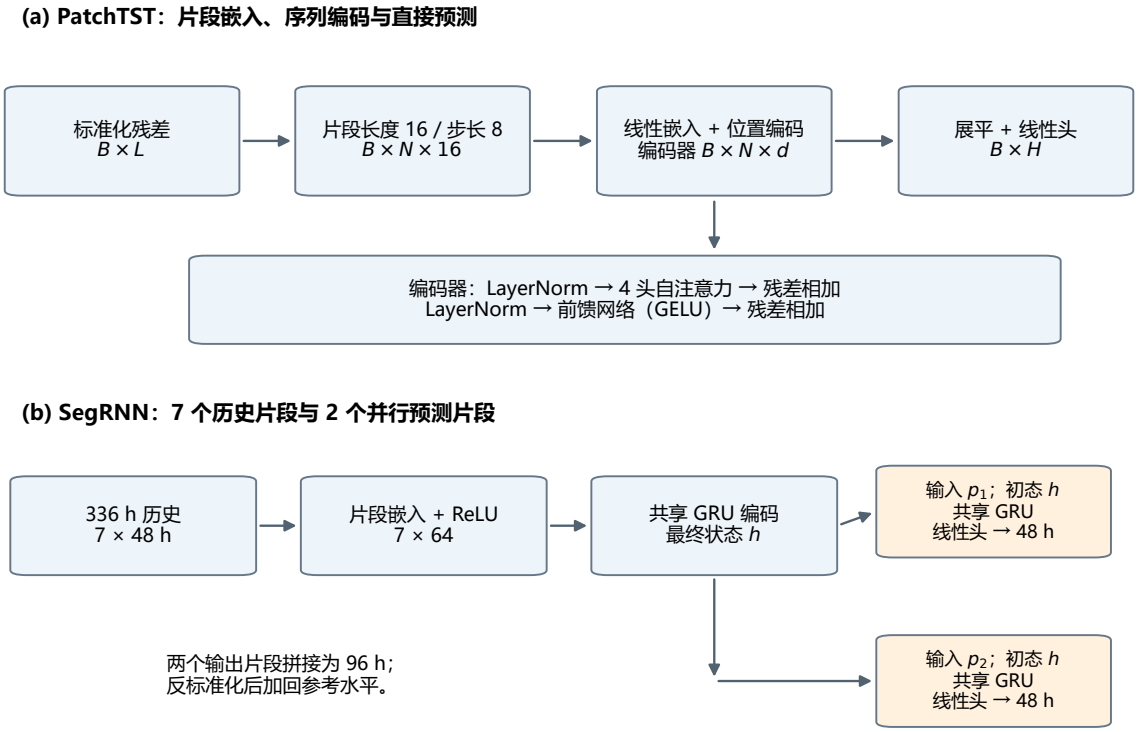


图 7: 两类片段模型的结构。PatchTST 沿片段序列编码，张量尺寸随历史长度变化；SegRNN 将 7 个历史片段压缩为状态，再以两个位置向量并行生成未来片段。两种结构均在输出端恢复输入窗口的参考水平。

A.5 片段循环网络

SegRNN 在片段之间更新循环状态，并行生成多个未来片段 [8]。输入为 336 h，按 48 h 划为 7 个非重叠片段。每段经 $48 \to 64$ 线性层和 ReLU 转为 64 维表示，单层 GRU 依次处理 7 段，得到最终状态 $h \in \mathbb{R}^{64}$。

未来 96 h 分成两个 48 h 片段。解码时把同一状态 h 复制给两个分支，每个分支使用独立的可学习位置向量 $p_j \in \mathbb{R}^{64}$ 作为单步 GRU 输入；编码与解码共享 GRU 参数。两个解码状态分别经过 dropout 与 $64 \to 48$ 的线性头，再拼接为 96 维输出。图 7(b) 展示这两个并行分支，共含 31,344 个参数。

SegRNN 比较两种参考水平：最近 24 h 均值，以及最后观测值。后者按 $x - y_t$ 和 $Y - y_t$ 构造残差，接近 SegRNN 的末值参考思路；两者均以训练窗口拟合固定尺度。它们用相同结构检验参考水平与分段循环预测之间的关系。

参考文献

[1] JIMÉNEZ-NAVARRO M J, MARTÍNEZ-BALLESTEROS M, MARTÍNEZ-ÁLVAREZ F, et al. A new deep learning architecture with inductive bias balance for transformer oil temperature forecasting [J/OL]. Journal of Big Data, 2023, 10(1). DOI: 10.1186/s40537-023-00745-0.

[2] ZHOU H, ZHANG S, PENG J, et al. Informer: beyond efficient transformer for long sequence time-series forecasting[C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 11106-11115. DOI: 10.1609/aaai.v35i12.17325.

[3] ZHOU H, ZHANG S, PENG J, et al. ETDataset: electricity transformer dataset[EB/OL]. 2021. https://github.com/zhouhaoyi/ETDataset.

[4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C/OL]// Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37. 2023: 11121-11128. DOI: 10.1609/aaai.v37i9.26317.

[5] NIE Y, NGUYEN N H, SINTHONG P, et al. A time series is worth 64 words: long-term forecasting with transformers[C]//International Conference on Learning Representations (ICLR). 2023.

[6] WU H, XU J, WANG J, et al. Autoformer: decomposition transformers with auto-correlation for long-term series forecasting[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021.

[7] ZHOU T, MA Z, WEN Q, et al. FEDformer: frequency enhanced decomposed transformer for long-term series forecasting[C]//Proceedings of Machine Learning Research: Vol. 162 Proceedings of the 39th International Conference on Machine Learning (ICML). 2022.

[8] LIN S, LIN W, WU W, et al. SegRNN: segment recurrent neural network for long-term time series forecasting[A/OL]. arXiv (2023). https://arxiv.org/abs/2308.11200.

[9] KIM T, KIM J, TAE Y, et al. Reversible instance normalization for accurate time-series forecasting against distribution shift[C/OL]//International Conference on Learning Representations (ICLR). 2022. https://openreview.net/forum?id=cGDAkQo1C0p.

[10] HUANG L, XU J, DARLOW L. How good can linear models be for time-series forecasting?[A/OL]. arXiv (2026). https://arxiv.org/abs/2606.27282.

[11] HAN L, YE H J, ZHAN D C. The capacity and robustness trade-off: revisiting the channel independent strategy for multivariate time series forecasting[A/OL]. arXiv (2023). https://arxiv.org/abs/2304.05206.